

15 mai 2026

Table des matières

Liste des Algorithmes

Préface

L'analyse numérique est l'art de résoudre des problèmes mathématiques *de façon approchée mais contrôlée*. Contrairement à l'analyse théorique qui établit l'existence et l'unicité des solutions, l'analyse numérique se préoccupe de les *calculer effectivement* et de *quantifier l'erreur commise*.

Ce cours couvre les fondements : arithmétique flottante, résolution de systèmes linéaires, interpolation, intégration numérique, équations différentielles ordinaires et problèmes aux valeurs propres. Chaque méthode est accompagnée de son analyse d'erreur, de son pseudo-code et d'implémentations en Python et Julia.

Prérequis. Analyse réelle I & II, algèbre linéaire, notions de programmation.

Références.

- QUARTERONI, Sacco, Saleri — *Numerical Mathematics*, Springer.
- SÜLI, Mayers — *An Introduction to Numerical Analysis*, Cambridge.
- TREFETHEN, Bau — *Numerical Linear Algebra*, SIAM.
- HIGHAM — *Accuracy and Stability of Numerical Algorithms*, SIAM.
- DEMAILLY — *Analyse Numérique et Équations Différentielles*, EDP Sciences.

Chapitre 1

Arithmétique Flottante, Erreurs et Stabilité

« *Le calcul numérique est l'art de donner la bonne réponse à un problème légèrement différent.* »

1.1 Exemple motivant

Calculons $f(x) = \frac{1-\cos x}{x^2}$ pour $x = 10^{-8}$ en double précision. Le résultat théorique est $\approx 0,5$, mais Python donne 0,0! La **cancellation catastrophique** entre 1 et $\cos x$ élimine tous les chiffres significatifs. Comprendre l'arithmétique flottante est indispensable.

1.2 Représentation des nombres en machine

Définition 1.1 (Nombre flottant). En base β avec t chiffres significatifs, un nombre flottant s'écrit :

$$x = \pm m \times \beta^e, \quad m = d_0.d_1d_2 \cdots d_{t-1}, \quad d_0 \neq 0,$$

où $e_{\min} \leq e \leq e_{\max}$ et $0 \leq d_i < \beta$.

Définition 1.2 (Standard IEEE 754).

Format	Bits	Mantisse	$\varepsilon_{\text{mach}}$
Simple précision	32	23+1 bits	$\approx 1,19 \times 10^{-7}$
Double précision	64	52+1 bits	$\approx 2,22 \times 10^{-16}$

Définition 1.3 (Epsilon machine). L'**epsilon machine** $\varepsilon_{\text{mach}}$ est le plus petit $\varepsilon > 0$ tel que $\text{fl}(1 + \varepsilon) > 1$:

$$\varepsilon_{\text{mach}} = \frac{1}{2}\beta^{1-t}.$$

Pour tout $x \in \mathbb{R}$ représentable, $\text{fl}(x) = x(1 + \delta)$ avec $|\delta| \leq \varepsilon_{\text{mach}}$.

1.3 Erreurs d'arrondi et propagation

Définition 1.4 (Erreur absolue et relative).

$$\text{Erreur absolue : } E_a = |x - \tilde{x}|, \quad (1.1)$$

$$\text{Erreur relative : } E_r = \frac{|x - \tilde{x}|}{|x|} \quad (x \neq 0). \quad (1.2)$$

Théorème 1.5 (Propagation des erreurs). Si $\tilde{x} = x(1 + \varepsilon_x)$ et $\tilde{y} = y(1 + \varepsilon_y)$:

- $\tilde{x} \cdot \tilde{y} \approx xy(1 + \varepsilon_x + \varepsilon_y)$: erreurs relatives s'ajoutent.
- $\tilde{x} - \tilde{y} \approx (x - y) + x\varepsilon_x - y\varepsilon_y$: si $x \approx y$, l'erreur relative explose.

Attention

La **cancellation catastrophique** se produit lors de la soustraction de nombres presque égaux. Exemple : $1 - \cos x$ pour x petit. Remède : utiliser $2 \sin^2(x/2)$.

1.4 Conditionnement d'un problème

Définition 1.6 (Conditionnement). Le **conditionnement** d'un problème f au point x est :

$$\kappa(f, x) = \left| \frac{xf'(x)}{f(x)} \right|.$$

Un problème est **bien conditionné** si $\kappa \sim 1$, **mal conditionné** si $\kappa \gg 1$.

Définition 1.7 (Conditionnement matriciel). Pour $Ax = b$:

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\|.$$

L'erreur relative sur x est amplifiée par $\text{cond}(A)$:

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}.$$

1.5 Stabilité numérique


Définition 1.8 (Algorithme stable). Un algorithme est **stable** s'il donne la solution exacte d'un problème **légèrement perturbé**. Il est **rétrograde stable** (backward stable) si la perturbation est de l'ordre de $\varepsilon_{\text{mach}}$.

Méthode

La précision du résultat dépend de deux facteurs :

1. Le **conditionnement** du problème (inhérent, on ne peut le changer).
2. La **stabilité** de l'algorithme (choix du programmeur).

Règle : erreur $\lesssim \text{cond} \times \varepsilon_{\text{mach}}$.



1.6 Implémentation

Python

<MINTED>

Julia

<MINTED>

1.7 Exercices

Exercice 1.1 (★ – Epsilon machine). Écrire un programme qui calcule $\varepsilon_{\text{mach}}$ par dichotomie. Comparer avec `np.finfo(float).eps`.

Exercice 1.2 (★ – Cancellation). Proposer un calcul stable de $\sqrt{x+1} - \sqrt{x}$ pour x grand. Vérifier numériquement.

Exercice 1.3 (★★ – Conditionnement). Calculer le conditionnement du problème $f(x) = \ln x$ au point $x = 1$. Interpréter.

Exercice 1.4 (★★ – Matrice de Hilbert). Soit H_n la matrice de Hilbert ($h_{ij} = 1/(i+j-1)$). Calculer $\text{cond}(H_n)$ pour $n = 2, \dots, 15$. Que constate-t-on ?

Exercice 1.5 (★★★ – Projet). Étudier la stabilité numérique de l'évaluation du polynôme $p(x) = \sum a_i x^i$ par l'algorithme de Horner vs. l'évaluation naïve. Comparer les erreurs relatives pour des polynômes de degré élevé.

Formules clés

$$\begin{aligned} \text{fl}(x) &= x(1 + \delta), \quad |\delta| \leq \varepsilon_{\text{mach}} & \varepsilon_{\text{mach}} &= \frac{1}{2}\beta^{1-t} \\ \kappa(f, x) &= |x f'(x)/f(x)| & \text{cond}(A) &= \|A\| \cdot \|A^{-1}\| \end{aligned}$$

Chapitre 2

Recherche de Racines

En 1669, Newton publie dans *De analysi per aequationes numero terminorum infinitas* une méthode pour calculer les racines d'équations polynomiales en s'aidant des tangentes : à chaque pas, on remplace la courbe par sa droite tangente, on résout cette équation linéaire élémentaire, et on recommence. La méthode est si efficace qu'elle converge quadratiquement — chaque itération double, grossièrement, le nombre de décimales correctes. Trois siècles plus tard, c'est encore l'algorithme par défaut pour résoudre les équations non linéaires dans n'importe quel logiciel scientifique, depuis MATLAB jusqu'aux GPS. Mais Newton n'a pas tout dit : la méthode peut diverger, osciller, ou converger vers la mauvaise racine selon le point de départ. Ce chapitre présente les algorithmes classiques (bissection, sécante, Newton, Newton modifié, point fixe), analyse leurs ordres de convergence, et discute des stratégies de globalisation qui rendent ces méthodes fiables en pratique.

2.1 Exemple motivant

Trouver x tel que $e^x = 3x$ revient à chercher la racine de $f(x) = e^x - 3x$. Aucune formule exacte n'existe : il faut une méthode numérique.

2.2 Méthode de bisection

Théorème 2.1 (Théorème des valeurs intermédiaires). *Si $f \in C([a, b])$ et $f(a)f(b) < 0$, alors $\exists c \in (a, b)$ tel que $f(c) = 0$.*

Algorithme 1 : Bisection

Entrée : f , a , b , tolérance ε
Sortie : Approximation de la racine c
while $b - a > \varepsilon$ **do**
 $c \leftarrow (a + b)/2$;
 if $f(a) \cdot f(c) < 0$ **then**
 $b \leftarrow c$
 else
 $a \leftarrow c$
 $\perp$
return c

Théorème 2.2 (Convergence de la bisection). *Après n itérations : $|c_n - x^*| \leq \frac{b-a}{2^{n+1}}$. La convergence est **linéaire** avec taux $1/2$.*


Démonstration. À chaque itération, l'intervalle est divisé par 2. Après n itérations, $|I_n| = (b - a)/2^n$ et $|c_n - x^*| \leq |I_n|/2$. $\square$

2.3 Méthode de Newton

Définition 2.3. L'itération de Newton pour $f(x) = 0$ est :

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Méthode de Newton



Algorithme 2 : Méthode de Newton

Entrée : f, f', x_0 , tolérance ε , $N_{\max}$

Sortie : Approximation x_n

pour $n = 0, 1, \dots, N_{\max}$ **faire**

$x_{n+1} \leftarrow x_n - f(x_n)/f'(x_n)$;

si $|x_{n+1} - x_n| < \varepsilon$ **alors**

return x_{n+1}

Théorème 2.4 (Convergence quadratique de Newton). Si $f \in C^2$, $f(x^*) = 0$, $f'(x^*) \neq 0$ et x_0 suffisamment proche de x^* , alors :

$$|e_{n+1}| \leq \frac{M}{2m} |e_n|^2,$$

où $e_n = x_n - x^*$, $M = \sup |f''|$, $m = \inf |f'|$ au voisinage de x^* .

Démonstration. Par Taylor : $0 = f(x^*) = f(x_n) + f'(x_n)(x^* - x_n) + \frac{f''(\xi_n)}{2}(x^* - x_n)^2$.
Divisant par $f'(x_n)$:

$$0 = \frac{f(x_n)}{f'(x_n)} + (x^* - x_n) + \frac{f''(\xi_n)}{2f'(x_n)} e_n^2.$$

Or $x_{n+1} = x_n - f(x_n)/f'(x_n)$, donc $e_{n+1} = x_{n+1} - x^* = -\frac{f''(\xi_n)}{2f'(x_n)} e_n^2$. $\square$

2.4 Méthode de la sécante

Définition 2.5. On remplace $f'(x_n)$ par une différence finie :

$$x_{n+1} = x_n - f(x_n) \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}.$$

Théorème 2.6. *L'ordre de convergence de la sécante est le **nombre d'or** $\varphi = (1 + \sqrt{5})/2 \approx 1,618$.*

2.5 Méthode du point fixe

Définition 2.7. Trouver $x = g(x)$. Itération : $x_{n+1} = g(x_n)$.

Théorème 2.8 (Théorème du point fixe de Banach). *Si $g : [a, b] \rightarrow [a, b]$ est une contraction ($|g'(x)| \leq L < 1$ sur $[a, b]$), alors g a un unique point fixe x^* et $x_n \rightarrow x^*$ avec :*

$$|x_n - x^*| \leq \frac{L^n}{1 - L} |x_1 - x_0|.$$

2.6 Comparaison des méthodes

Méthode	Ordre	Appels f	Robustesse
Bissection	1 (linéaire)	1/it.	Très robuste
Newton	2 (quadratique)	$f + f'$ /it.	Sensible à x_0
Sécante	$\varphi \approx 1,618$	1/it.	Modérée

2.7 Exemple numérique

Racine de $f(x) = e^x - 3x$ avec $x_0 = 2$ (Newton) :

n	x_n	$f(x_n)$	$ x_n - x_{n-1} $
0	2.000000	1.389056	—
1	1.373418	0.225698	0.627
2	1.524247	-0.046	0.151
3	1.512127	-0.000374	0.012
4	1.512135	$< 10^{-9}$	8×10^{-6}

2.8 Implémentation

Python

<MINTED>

Julia

<MINTED>

2.9 Exercices

Exercice 2.1 (*). Trouver $\sqrt{2}$ par Newton appliqué à $f(x) = x^2 - 2$. Combien d'itérations pour 15 décimales ?

Exercice 2.2 (★★). Montrer que Newton appliqué à $f(x) = x^2$ converge linéairement (racine double). Généraliser : que se passe-t-il quand $f'(x^*) = 0$?

Exercice 2.3 (★★). Démontrer l'ordre φ de la sécante en posant $e_{n+1} \approx C e_n^p$ et en résolvant $p^2 - p - 1 = 0$.

Exercice 2.4 (★★★ – Projet). Implémenter la méthode de Brent (combinaison bisection + sécante). Comparer avec les méthodes simples sur 10 fonctions test.

Formules clés

$$\text{Bisection : } |e_n| \leq \frac{b-a}{2^{n+1}}$$

$$\text{Newton : } x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}, \quad |e_{n+1}| \leq C|e_n|^2$$

$$\text{Sécante : } x_{n+1} = x_n - f(x_n) \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}, \quad \text{ordre } \varphi$$

Chapitre 3

Méthodes Directes pour Systèmes Linéaires

En 1810, Carl Friedrich Gauss publie dans *Disquisitio de elementis ellipticis Palladis* la méthode d'élimination qui porte aujourd'hui son nom : pour résoudre un système de douze équations à douze inconnues issu de l'orbite de l'astéroïde Pallas, il transforme le système par opérations élémentaires sur les lignes jusqu'à obtenir une forme triangulaire qu'on résout par substitution. La même idée, écrite proprement, donne la décomposition LU. Un siècle plus tard, en 1910, le commandant André-Louis Cholesky — ingénieur géographe français mort à la guerre en 1918 — découvre que pour les matrices symétriques définies positives, on peut se passer de la moitié des opérations en exploitant la symétrie. Sa méthode, publiée à titre posthume, est encore la pierre angulaire des calculs en moindres carrés. Ce chapitre développe les factorisations LU, LDL^T et Cholesky, analyse leur coût, leur stabilité numérique (pivots, perturbations), et présente les techniques de pivotement partiel qui garantissent la robustesse.

3.1 Exemple motivant

Un circuit électrique à n nœuds produit un système $Ax = b$ de n équations. Pour $n = 1000$, il faut une méthode systématique et efficace.

3.2 Élimination de Gauss et factorisation LU

Définition 3.1 (Factorisation LU). Trouver L triangulaire inférieure (avec $\ell_{ii} = 1$) et U triangulaire supérieure telles que $A = LU$. Alors $Ax = b$ se résout par $Ly = b$ (descente) puis $Ux = y$ (remontée).

Algorithme 3 : Factorisation LU (sans pivot)

Entrée : Matrice $A \in \mathbb{R}^{n \times n}$

Sortie : L, U tels que $A = LU$

pour $k = 1, \dots, n-1$ **faire**
 pour $i = k+1, \dots, n$ **faire**
 $\ell_{ik} \leftarrow a_{ik}/a_{kk};$
 pour $j = k+1, \dots, n$ **faire**
 $a_{ij} \leftarrow a_{ij} - \ell_{ik} \cdot a_{kj};$

$U \leftarrow$ partie triangulaire supérieure de A ;

Théorème 3.2 (Existence de LU). *Si toutes les sous-matrices principales de A sont inversibles, alors la factorisation LU existe et est unique.*

Théorème 3.3 (Coût). *La factorisation LU coûte $\frac{2n^3}{3} + \mathcal{O}(n^2)$ opérations flottantes.*

Démonstration. L'étape k effectue $(n-k)^2$ multiplications et soustractions. Total : $\sum_{k=1}^{n-1} 2(n-k)^2 = 2 \sum_{j=1}^{n-1} j^2 = \frac{2n^3}{3} + \mathcal{O}(n^2)$. $\square$

3.3 Pivot partiel

Attention

Sans pivotement, l'algorithme peut être instable (division par un petit pivot). Le **pivot partiel** permute les lignes pour maximiser $|a_{kk}|$.

On obtient $PA = LU$ où P est une matrice de permutation.

Théorème 3.4 (Stabilité). *Avec pivot partiel, l'élimination de Gauss est **rétrograde stable** :*

$$(A + \Delta A)\hat{x} = b, \quad \|\Delta A\| \leq g(n) \varepsilon_{\text{mach}} \|A\|,$$

où $g(n)$ est le facteur de croissance (borné par 2^{n-1} en théorie, rarement dépassé en pratique).

3.4 Factorisation de Cholesky

Théorème 3.5 (Factorisation de Cholesky). *Si A est **symétrique définie positive** (SDP), alors il existe une unique matrice triangulaire inférieure L à coefficients diagonaux positifs telle que $A = LL^\top$.*

Démonstration. Par récurrence sur n . Écrivons $A = \begin{pmatrix} a_{11} & \mathbf{v}^\top \\ \mathbf{v} & A' \end{pmatrix}$. Comme A SDP, $a_{11} > 0$. Posons $\ell_{11} = \sqrt{a_{11}}$, $\mathbf{l} = \mathbf{v}/\ell_{11}$. Alors $A' - \mathbf{l}\mathbf{l}^\top$ est SDP de taille $(n-1) \times (n-1)$ et on applique l'hypothèse de récurrence. $\square$

Algorithme 4 : Factorisation de Cholesky

Entrée : A SDP, $n \times n$

Sortie : L telle que $A = LL^\top$

pour $j = 1, \dots, n$ **faire**

$\ell_{jj} \leftarrow \sqrt{a_{jj} - \sum_{k=1}^{j-1} \ell_{jk}^2}$;

pour $i = j + 1, \dots, n$ **faire**

$\ell_{ij} \leftarrow \frac{1}{\ell_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} \ell_{jk} \right)$;

Théorème 3.6 (Coût de Cholesky). $\frac{n^3}{3} + \mathcal{O}(n^2)$: deux fois moins que LU .

3.5 Exemple numérique

$$A = \begin{pmatrix} 4 & 2 \\ 2 & 5 \end{pmatrix}, b = \begin{pmatrix} 8 \\ 9 \end{pmatrix}. \text{ Cholesky : } L = \begin{pmatrix} 2 & 0 \\ 1 & 2 \end{pmatrix}.$$

Descente $Ly = b$: $y_1 = 4$, $y_2 = (9 - 1 \cdot 4)/2 = 2,5$. Remontée $L^\top x = y$: $x_2 = 2,5/2 = 1,25$, $x_1 = (4 - 1 \cdot 1,25)/2 = 1,375$.

3.6 Implémentation

Python

<MINTED>

Julia

<MINTED>

3.7 Exercices

Exercice 3.1 (*). Factoriser $A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 8 & 14 \\ 3 & 14 & 34 \end{pmatrix}$ en LU à la main. Vérifier.

Exercice 3.2 (**). Montrer que si A est SDP, tous ses pivots dans l'élimination de Gauss sont positifs (sans pivotement nécessaire).

Exercice 3.3 (**). Comparer les temps de calcul de LU vs. Cholesky pour $n = 100, 500, 1000, 2000$ sur des matrices SDP aléatoires. Vérifier le rapport ~ 2 .

Exercice 3.4 (***) – Projet). Implémenter la factorisation LU bande pour des matrices tridiagonales (algorithme de Thomas). Appliquer à la discrétisation de $-u'' = f$.

Formules clés

$$A = LU \quad (\text{coût } \frac{2n^3}{3})$$

$$A = LL^\top \quad (\text{Cholesky, coût } \frac{n^3}{3})$$

$$PA = LU \quad (\text{pivot partiel})$$

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\|, \quad \frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}$$

Chapitre 4

Méthodes Itératives pour Systèmes Linéaires

Quand les ingénieurs d'EDF doivent résoudre un système linéaire pour simuler un réseau électrique national — plusieurs millions d'inconnues — les méthodes directes deviennent infaisables : la décomposition LU coûte $O(n^3)$ et remplit la mémoire. La solution, anticipée par Jacobi en 1845 puis par Gauss et Seidel, consiste à abandonner l'idée d'obtenir la solution exacte en un nombre fini d'étapes, et à accepter une suite d'approximations qui converge vers la vraie solution. Pour une matrice creuse, cette stratégie est gagnante : chaque itération ne coûte que $O(\text{nnz})$, et seules quelques dizaines d'itérations suffisent en pratique. Ce chapitre présente les méthodes itératives classiques (Jacobi, Gauss-Seidel, relaxation successive SOR), puis les méthodes de Krylov modernes (gradient conjugué, GMRES) qui dominent aujourd'hui le calcul scientifique haute performance. La théorie de convergence repose sur le rayon spectral de la matrice d'itération.

4.1 Exemple motivant

En éléments finis, la matrice A est creuse ($\mathcal{O}(n)$ coefficients non nuls sur n^2). LU coûte $\mathcal{O}(n^3)$, inacceptable pour $n = 10^6$. Les méthodes itératives exploitent la structure creuse : chaque itération coûte $\mathcal{O}(n)$.

4.2 Principe général

Définition 4.1 (Méthode de décomposition). On écrit $A = M - N$ avec M inversible facile. L'itération est :

$$Mx^{(k+1)} = Nx^{(k)} + b, \quad \text{soit} \quad x^{(k+1)} = Gx^{(k)} + c,$$

où $G = M^{-1}N$ est la **matrice d'itération** et $c = M^{-1}b$.

Théorème 4.2 (Convergence). *La méthode converge pour tout $x^{(0)}$ si et seulement si $\rho(G) < 1$ (rayon spectral).*

Démonstration. $e^{(k)} = x^{(k)} - x^* = G^k e^{(0)}$. Or $\|G^k\| \rightarrow 0 \iff \rho(G) < 1$. □

4.3 Méthode de Jacobi

Définition 4.3. $A = D - E - F$ (diagonale, triangulaire inf., triangulaire sup.). $M = D :$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

Matrice d'itération : $G_J = D^{-1}(E + F)$.

4.4 Méthode de Gauss–Seidel

Définition 4.4. $M = D - E :$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

Matrice d'itération : $G_{GS} = (D - E)^{-1}F$.

Théorème 4.5 (Convergence pour matrices SDP). *Si A est SDP, Gauss–Seidel converge.*

Théorème 4.6 (Convergence pour matrices à diagonale dominante). *Si A est à diagonale strictement dominante ($|a_{ii}| > \sum_{j \neq i} |a_{ij}|$), alors Jacobi et Gauss–Seidel convergent.*

4.5 Relaxation (SOR)

Définition 4.7. On introduit un paramètre $\omega \in (0, 2)$:

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

$\omega = 1$: Gauss–Seidel. $\omega > 1$: sur-relaxation. $\omega < 1$: sous-relaxation.

Théorème 4.8. *SOR converge ssi $0 < \omega < 2$. L' ω optimal dépend de $\rho(G_J)$.*

4.6 Méthode du gradient conjugué

Définition 4.9. Pour A SDP, résoudre $Ax = b$ équivaut à minimiser $\phi(x) = \frac{1}{2}x^\top Ax - b^\top x$.

Algorithme 5 : Gradient conjugué

Entrée : A SDP, b , x_0 , tolérance ε

Sortie : $x \approx A^{-1}b$

$r_0 \leftarrow b - Ax_0$, $p_0 \leftarrow r_0$;

pour $k = 0, 1, 2, \dots$ **faire**

$\alpha_k \leftarrow \frac{r_k^\top r_k}{p_k^\top A p_k}$;

$x_{k+1} \leftarrow x_k + \alpha_k p_k$;

$r_{k+1} \leftarrow r_k - \alpha_k A p_k$;

si $\|r_{k+1}\| < \varepsilon$ **alors**

return x_{k+1}

$\beta_k \leftarrow \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}$;

$p_{k+1} \leftarrow r_{k+1} + \beta_k p_k$;

Théorème 4.10 (Convergence du gradient conjugué). *En arithmétique exacte, CG converge en au plus n itérations. L'erreur vérifie :*

$$\|e_k\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|e_0\|_A, \quad \kappa = \text{cond}_2(A).$$

4.7 Implémentation

Python

<MINTED>

Julia

<MINTED>

4.8 Exercices

Exercice 4.1 (*). Appliquer 3 itérations de Jacobi et Gauss-Seidel au système $\begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix} x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$, $x^{(0)} = (0, 0)^\top$.

Exercice 4.2 (**). Montrer que pour une matrice tridiagonale T_n de taille n , $\rho(G_J) = \cos(\pi/(n+1))$. En déduire le nombre d'itérations de Jacobi pour une précision ε .

Exercice 4.3 (*** – Projet). Comparer Jacobi, Gauss-Seidel, SOR et CG pour la discrétisation 2D du Laplacien $-\Delta u = f$ sur $[0, 1]^2$. Tracer le nombre d'itérations en fonction de n .

Formules clés

$$\text{Jacobi : } x^{(k+1)} = D^{-1}(b - (A - D)x^{(k)})$$

$$\text{Gauss-Seidel : } G = (D - E)^{-1}F$$

$$\text{CG : } \|e_k\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|e_0\|_A$$

Chapitre 5

Interpolation Polynomiale

En 1901, le mathématicien allemand Carl Runge publie un résultat surprenant : si l'on interpole la fonction $f(x) = 1/(1 + 25x^2)$ sur $[-1, 1]$ par un polynôme de degré n aux points équidistants, l'erreur d'interpolation *diverge* lorsque $n \rightarrow \infty$. Plus on prend de points, pire est l'approximation aux bords. Ce phénomène — qu'on appelle aujourd'hui le phénomène de Runge — a stoppé net l'usage naïf des polynômes d'interpolation pour le calcul d'erreur en physique et en astronomie, et a orienté les mathématiciens vers les nœuds de Chebyshev, les splines, et la théorie de la stabilité numérique de l'interpolation. Ce chapitre construit l'interpolation polynomiale (forme de Lagrange, forme de Newton, différences divisées), analyse l'erreur, présente l'interpolation par splines cubiques — la solution standard pour le tracé fluide en CAO — et termine par les bases d'interpolation modernes utilisées en éléments finis.

5.1 Exemple motivant

On dispose de mesures de température à 5 instants. On veut estimer la température à un instant intermédiaire. L'interpolation polynomiale construit un polynôme passant exactement par les points mesurés.

5.2 Problème d'interpolation

Théorème 5.1 (Existence et unicité). *Étant donnés $n+1$ points distincts $(x_0, y_0), \dots, (x_n, y_n)$, il existe un **unique** polynôme $p_n \in \mathcal{P}_n$ tel que $p_n(x_i) = y_i$ pour tout i .*

Démonstration. La matrice de Vandermonde $V_{ij} = x_i^j$ est inversible car $\det(V) = \prod_{i>j} (x_i - x_j) \neq 0$. $\square$

5.3 Forme de Lagrange

Définition 5.2.

$$p_n(x) = \sum_{i=0}^n y_i L_i(x), \quad L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}.$$

Les L_i sont les **polynômes de base de Lagrange** : $L_i(x_j) = \delta_{ij}$.

5.4 Forme de Newton

Définition 5.3 (Différences divisées).

$$f[x_i] = f(x_i), \quad f[x_i, \dots, x_{i+k}] = \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i}.$$

Définition 5.4 (Forme de Newton).

$$p_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \dots + f[x_0, \dots, x_n] \prod_{j=0}^{n-1} (x - x_j).$$

Évaluation par l'algorithme de Horner généralisé : $\mathcal{O}(n)$ opérations.

5.5 Erreur d'interpolation

Théorème 5.5 (Erreur d'interpolation). Si $f \in C^{n+1}([a, b])$, alors pour tout $x \in [a, b]$:


$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{i=0}^n (x - x_i),$$

où $\xi_x \in (a, b)$ dépend de x .

Démonstration. Posons $w(t) = \prod (t - x_i)$ et $\varphi(t) = f(t) - p_n(t) - \lambda w(t)$ avec λ choisi pour que $\varphi(x) = 0$ (pour un x fixé $\neq x_i$). Alors φ s'annule en $n+2$ points. Par Rolle appliqué $n+1$ fois, $\varphi^{(n+1)}$ s'annule en un point ξ . Or $\varphi^{(n+1)} = f^{(n+1)} - \lambda(n+1)!$, d'où $\lambda = f^{(n+1)}(\xi)/(n+1)!$. $\square$

Attention

Le **phénomène de Runge** : pour $f(x) = 1/(1 + 25x^2)$ sur $[-1, 1]$ avec des nœuds équidistants, l'erreur d'interpolation *diverge* quand $n \rightarrow \infty$ près des bords.



5.6 Nœuds de Tchebychev

Définition 5.6. Les nœuds de Tchebychev sur $[-1, 1]$:

$$x_k = \cos\left(\frac{2k+1}{2(n+1)}\pi\right), \quad k = 0, \dots, n.$$

Ils minimisent $\max_{x \in [-1, 1]} |\prod (x - x_i)|$.

Théorème 5.7. Avec les nœuds de Tchebychev : $\max |w(x)| \leq 2^{-n}$, ce qui évite le phénomène de Runge pour les fonctions analytiques.

5.7 Splines cubiques

Définition 5.8 (Spline cubique d'interpolation). $s \in C^2([a, b])$, $s|_{[x_i, x_{i+1}]} \in \mathcal{P}_3$, $s(x_i) = y_i$. Conditions aux bords :

- Naturelle : $s''(x_0) = s''(x_n) = 0$.
- Clampée : $s'(x_0) = f'(x_0)$, $s'(x_n) = f'(x_n)$.

Théorème 5.9 (Erreur spline cubique). Si $f \in C^4$ et $h = \max(x_{i+1} - x_i)$:

$$\|f - s\|_\infty \leq \frac{5}{384} h^4 \|f^{(4)}\|_\infty.$$

5.8 Implémentation

Python

<MINTED>

Julia

<MINTED>

5.9 Exercices

Exercice 5.1 (*). Construire le polynôme de Lagrange passant par $(0, 1)$, $(1, 3)$, $(2, 7)$ et vérifier.

Exercice 5.2 (**). Démontrer le théorème ?? en détail.

Exercice 5.3 (**). Comparer l'erreur d'interpolation avec nœuds équidistants vs. Tchebychev pour $f(x) = 1/(1 + 25x^2)$, $n = 5, 10, 15, 20$.

Exercice 5.4 (*** – Projet). Implémenter l'interpolation de Hermite (données de f et f'). Appliquer à la construction de courbes de Bézier.

Formules clés

$$L_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}$$
$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod (x - x_i)$$
$$x_k^{\text{Tcheb}} = \cos\left(\frac{2k+1}{2(n+1)}\pi\right)$$
$$\|f - s\|_\infty \leq \frac{5}{384} h^4 \|f^{(4)}\|_\infty$$

Chapitre 6

Approximation — Moindres Carrés et Tchebychev

En 1854, Pafnouti Tchebychev visite les manufactures textiles de Lille et observe que les pièces métalliques des métiers à tisser s'usent inégalement parce que leur mouvement n'est qu'approximativement rectiligne. Le problème théorique sous-jacent : trouver, parmi tous les polynômes de degré donné dont le coefficient dominant vaut 1, celui dont l'amplitude maximale sur un intervalle est minimale. Tchebychev résout le problème, et la suite de polynômes qu'il obtient — les polynômes de Tchebychev — s'avère être l'une des découvertes les plus fertiles de l'analyse appliquée du XIX^e siècle. La même mathématique optimise aujourd'hui les filtres numériques, les méthodes spectrales en EDP, et les approximations rationnelles en calcul scientifique. Ce chapitre traite l'approximation au sens des moindres carrés et au sens minimax, présente les polynômes orthogonaux classiques (Legendre, Tchebychev, Hermite) et leurs applications à la quadrature et à la résolution d'EDP.

6.1 Exemple motivant

On a 100 mesures expérimentales bruitées. Faire passer un polynôme de degré 99 par tous les points serait absurde (sur-ajustement). On cherche un polynôme de faible degré qui *approche* les données au mieux : c'est l'approximation par moindres carrés.

6.2 Approximation au sens des moindres carrés

Définition 6.1 (Problème des moindres carrés). Étant donnés $(x_i, y_i)_{i=1}^m$ et des fonctions $\varphi_0, \dots, \varphi_n$ ($n < m$), trouver $c_0, \dots, c_n$ minimisant :

$$S(c) = \sum_{i=1}^m \left(y_i - \sum_{j=0}^n c_j \varphi_j(x_i) \right)^2 = \|y - Ac\|_2^2,$$

où $A_{ij} = \varphi_j(x_i)$.

Théorème 6.2 (Équations normales). *Le minimum est atteint pour c^* solution de :*

$$A^\top A c^* = A^\top y.$$

La matrice $A^\top A$ est SDP si A est de rang plein.

Démonstration. $\nabla_c \|y - Ac\|^2 = -2A^\top(y - Ac) = 0$ donne $A^\top Ac = A^\top y$. □

6.3 Polynômes orthogonaux

Définition 6.3. Pour le produit scalaire $\langle f, g \rangle = \int_a^b f(x)g(x)w(x)dx$ (ou discret), les polynômes orthogonaux évitent le mauvais conditionnement de $A^\top A$.

Théorème 6.4 (Projection orthogonale). Si $\{\varphi_j\}$ est une base orthonormale : $c_j = \langle y, \varphi_j \rangle$.

6.4 Meilleure approximation uniforme

Définition 6.5. Trouver $p^* \in \mathcal{P}_n$ minimisant $\|f - p\|_\infty = \max_{x \in [a,b]} |f(x) - p(x)|$.

Théorème 6.6 (Théorème d'équioscillation de Tchebychev). p^* est la meilleure approximation uniforme de degré n ssi l'erreur $f - p^*$ équioscille en au moins $n + 2$ points.

6.5 Implémentation

Python

<MINTED>

6.6 Exercices

Exercice 6.1 (*). Ajuster une droite $y = a + bx$ aux données $(1, 2, 1)$, $(2, 3, 8)$, $(3, 6, 2)$, $(4, 7, 9)$, $(5, 10, 3)$ par moindres carrés. Calculer le RMSE.

Exercice 6.2 (**). Montrer que le conditionnement de $A^\top A$ est le carré du conditionnement de A . Pourquoi est-il préférable d'utiliser la factorisation QR ?

Exercice 6.3 (*** – Projet). Implémenter l'approximation de Tchebychev par l'algorithme de Remez. Comparer avec les moindres carrés sur des fonctions test.

Formules clés

$$\min_c \|y - Ac\|_2^2 \implies A^\top Ac = A^\top y$$

$$\text{cond}(A^\top A) = \text{cond}(A)^2$$

Équioscillation : erreur change de signe en $n + 2$ points

Chapitre 7

Dérivation et Intégration Numérique

Quand les ingénieurs du Met Office britannique numérisent les premières prévisions météorologiques dans les années 1950, ils découvrent vite qu'intégrer numériquement les équations atmosphériques avec la règle des trapèzes coûte trop cher pour la précision requise. Werner Romberg, mathématicien suédois, propose en 1955 une astuce élégante : combiner des estimations trapézoïdales à plusieurs pas pour annuler successivement les termes d'erreur d'ordres croissants — l'extrapolation de Richardson appliquée à la quadrature. Le résultat est qu'avec un nombre logarithmique d'évaluations, on atteint une précision qui aurait demandé des milliers d'évaluations à la méthode brute. Ce chapitre couvre les formules de différentiation numérique (différences finies, dérivées d'ordre supérieur, stabilité), les méthodes de quadrature de Newton-Cotes (trapèze, Simpson), l'extrapolation de Romberg, et la quadrature adaptative — l'algorithme par défaut dans `scipy.integrate`.

7.1 Exemple motivant

Calculer $\int_0^1 e^{-x^2} dx$: pas de primitive en forme close. On utilise des formules de quadrature. De même, $f'(x)$ peut être approchée par des différences finies lorsque f n'est connue que numériquement.

7.2 Dérivation numérique

Définition 7.1 (Différences finies).

$$f'(x) \approx \frac{f(x+h) - f(x)}{h} \quad (\text{progressive, } \mathcal{O}(h)) \quad (7.1)$$

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h} \quad (\text{centrée, } \mathcal{O}(h^2)) \quad (7.2)$$

$$f''(x) \approx \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} \quad (\mathcal{O}(h^2)) \quad (7.3)$$

Théorème 7.2 (Erreur de la différence centrée). Si $f \in C^3$: $\frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{6} f'''(\xi)$.

Attention

Diminuer h améliore l'erreur de troncature mais augmente l'erreur d'arrondi. Le h optimal est $h^* \sim \varepsilon_{\text{mach}}^{1/3} \approx 6 \times 10^{-6}$ en double précision.

7.3 Formules de Newton–Cotes

Principe : remplacer f par son polynôme d'interpolation sur $[a, b]$ et intégrer.

7.3.1 Règle du trapèze

Définition 7.3.

$$\int_a^b f(x) dx \approx \frac{b-a}{2} [f(a) + f(b)].$$

Erreur : $-\frac{(b-a)^3}{12} f''(\xi)$.

7.3.2 Règle de Simpson

Définition 7.4.

$$\int_a^b f(x) dx \approx \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right].$$

Erreur : $-\frac{(b-a)^5}{2880} f^{(4)}(\xi)$.

Théorème 7.5 (Formule de Simpson — degré d'exactitude). *Simpson est exacte pour les polynômes de degré ≤ 3 (un degré de mieux que prévu).*

7.4 Formules composites

Définition 7.6 (Trapèze composite). n sous-intervalles, $h = (b-a)/n$:

$$T_n(f) = \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right].$$

Erreur : $-\frac{(b-a)h^2}{12} f''(\xi) = \mathcal{O}(h^2)$.

Définition 7.7 (Simpson composite). n pairs de sous-intervalles, $h = (b-a)/n$:

$$S_n(f) = \frac{h}{3} \left[f(a) + 4 \sum_{\text{imp}} f(x_i) + 2 \sum_{\text{pair}} f(x_i) + f(b) \right].$$

Erreur : $\mathcal{O}(h^4)$.

7.5 Extrapolation de Richardson

Théorème 7.8. Si $T(h) = I + c_1 h^2 + c_2 h^4 + \dots$, alors $\frac{4T(h/2) - T(h)}{3} = I + \mathcal{O}(h^4)$. C'est la formule de Simpson !

7.6 Exemple numérique

$$I = \int_0^1 e^{-x^2} dx \approx 0,746824.$$

n	Trapèze T_n	Simpson S_n	Erreur Simpson
2	0.731531	0.747180	$3,6 \times 10^{-4}$
4	0.742984	0.746831	$7,0 \times 10^{-6}$
8	0.745866	0.746824	$1,1 \times 10^{-7}$
16	0.746584	0.746824	$1,7 \times 10^{-9}$

7.7 Implémentation

Python

<MINTED>

Julia

<MINTED>

7.8 Exercices

Exercice 7.1 (*). Calculer $\int_0^\pi \sin x \, dx$ par trapèze et Simpson composites ($n = 4$). Comparer à la valeur exacte.

Exercice 7.2 (**). Démontrer que Simpson est exacte pour les polynômes de degré 3.

Exercice 7.3 (**). Vérifier numériquement l'ordre $\mathcal{O}(h^2)$ du trapèze et $\mathcal{O}(h^4)$ de Simpson par un tableau d'erreurs.

Exercice 7.4 (***) – Projet). Implémenter l'intégration adaptative (Simpson adaptatif) et comparer avec `scipy.integrate.quad`.

Formules clés

$$T_n = \frac{h}{2}[f(a) + 2 \sum f(x_i) + f(b)], \quad E = \mathcal{O}(h^2)$$

$$S_n = \frac{h}{3}[f(a) + 4 \sum_{\text{imp}} + 2 \sum_{\text{pair}} + f(b)], \quad E = \mathcal{O}(h^4)$$

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}, \quad E = \mathcal{O}(h^2)$$

Chapitre 8

Quadrature de Gauss

En 1814, Carl Friedrich Gauss publie un mémoire sur l'intégration approchée des fonctions par interpolation polynomiale aux racines des polynômes orthogonaux. Le résultat est spectaculaire : pour intégrer un polynôme de degré $2n - 1$, n évaluations bien choisies suffisent et donnent le résultat *exact*, contre les $2n$ évaluations qu'exigerait Simpson. Cette efficacité maximale n'est pas une coïncidence — elle découle d'une propriété profonde des polynômes orthogonaux que Gauss démontre en quelques pages. Aujourd'hui, la quadrature de Gauss est l'épine dorsale de la méthode des éléments finis : chaque code de simulation mécanique (ANSYS, Abaqus, Code_Aster) en évalue des milliards par seconde. Ce chapitre construit les formules de Gauss-Legendre, Gauss-Tchebychev et Gauss-Hermite, démontre leur ordre de précision optimal, et présente les variantes adaptatives (Gauss-Kronrod) utilisées en calcul automatique.

8.1 Exemple motivant

Les formules de Newton-Cotes (nœuds fixés) atteignent un degré d'exactitude n ou $n + 1$. En choisissant **les nœuds librement**, on peut atteindre le degré $2n + 1$ avec $n + 1$ points — c'est la quadrature de Gauss.

8.2 Principe

Définition 8.1 (Quadrature de Gauss). Trouver $n+1$ nœuds $x_0, \dots, x_n$ et poids $w_0, \dots, w_n$ tels que :

$$\int_{-1}^1 f(x) dx \approx \sum_{i=0}^n w_i f(x_i)$$

soit exacte pour tout $f \in \mathcal{P}_{2n+1}$.

Théorème 8.2 (Théorème fondamental). *Les nœuds de la quadrature de Gauss-Legendre à $n + 1$ points sont les racines du polynôme de Legendre P_{n+1} . Le degré d'exactitude est $2n + 1$.*

Esquisse. Soit $f \in \mathcal{P}_{2n+1}$. Division euclidienne : $f = q \cdot P_{n+1} + r$ avec $\deg q \leq n$, $\deg r \leq n$. Alors $\int_{-1}^1 f = \int_{-1}^1 q P_{n+1} + \int_{-1}^1 r$. Par orthogonalité de P_{n+1} à $\mathcal{P}_n$: $\int q P_{n+1} = 0$. Et $\sum w_i f(x_i) = \sum w_i r(x_i)$ car $P_{n+1}(x_i) = 0$. Les poids sont choisis pour que la formule soit exacte sur $\mathcal{P}_n$, donc $\sum w_i r(x_i) = \int r$. $\square$

8.3 Nœuds et poids

$n + 1$	Nœuds x_i	Poids w_i
1	0	2
2	$\pm 1/\sqrt{3}$	1, 1
3	$0, \pm\sqrt{3/5}$	8/9, 5/9, 5/9

8.4 Gauss–Legendre, Gauss–Laguerre, Gauss–Hermite

Définition 8.3. Pour $\int_a^b f(x)w(x) dx$ avec poids w :

- **Gauss–Legendre** : $w(x) = 1$ sur $[-1, 1]$.
- **Gauss–Laguerre** : $w(x) = e^{-x}$ sur $[0, \infty)$.
- **Gauss–Hermite** : $w(x) = e^{-x^2}$ sur $(-\infty, \infty)$.

8.5 Erreur

Théorème 8.4. L'erreur de Gauss–Legendre à $n + 1$ points est :

$$E_n(f) = \frac{2^{2n+3}[(n+1)!]^4}{(2n+3)[(2n+2)!]^3} f^{(2n+2)}(\xi).$$

8.6 Changement d'intervalle

Pour $\int_a^b f(x) dx$, le changement $x = \frac{b-a}{2}t + \frac{a+b}{2}$ ramène à $[-1, 1]$:

$$\int_a^b f(x) dx = \frac{b-a}{2} \int_{-1}^1 f\left(\frac{b-a}{2}t + \frac{a+b}{2}\right) dt.$$

8.7 Implémentation

Python

<MINTED>

Julia

<MINTED>

8.8 Exercices

Exercice 8.1 (★). Calculer $\int_0^1 x^3 dx$ par Gauss–Legendre à 2 points. Vérifier l'exactitude.

Exercice 8.2 (★★). Montrer que les poids de Gauss sont toujours positifs.

Exercice 8.3 (★★★ – Projet). Comparer la convergence de Simpson composite (n points) et Gauss–Legendre (n points) pour $\int_0^1 e^{-x^2} dx$. Tracer l'erreur en échelle log-log.

Formules clés

$$\int_{-1}^1 f(x) dx \approx \sum_{i=0}^n w_i f(x_i), \quad \text{exacte pour } \mathcal{P}_{2n+1}$$
$$\int_a^b f(x) dx = \frac{b-a}{2} \int_{-1}^1 f\left(\frac{b-a}{2}t + \frac{a+b}{2}\right) dt$$

Chapitre 9

Résolution Numérique des EDO

En juillet 1969, les ordinateurs de bord du module lunaire Eagle d'Apollo 11 résolvent en temps réel un système d'équations différentielles ordinaires pour calculer la trajectoire de descente vers la Mer de la Tranquillité. La méthode utilisée est dérivée du schéma de Runge-Kutta, publié par Carl Runge en 1895 et raffiné par Wilhelm Kutta en 1901. La beauté de Runge-Kutta tient en une idée : remplacer la dérivée brute du schéma d'Euler par une combinaison de pentes évaluées en plusieurs points intermédiaires, et obtenir ainsi un ordre de convergence arbitrairement élevé. Ce chapitre construit les schémas explicites (Euler, RK2, RK4) puis les schémas implicites (Euler arrière, Crank-Nicolson, BDF) pour les problèmes raides, analyse leur stabilité absolue, et présente les stratégies de pas adaptatif — l'algorithme par défaut dans Matlab `ode45` et scipy `solve_ivp`.

9.1 Exemple motivant

Le mouvement d'un pendule simple est régi par $\theta'' = -\frac{g}{L} \sin \theta$. Pour de grandes oscillations, pas de solution analytique. On discrétise en temps et on itère.

9.2 Problème de Cauchy

Définition 9.1.

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0, \quad t \in [t_0, T].$$

Discrétisation : $t_n = t_0 + nh$, $y_n \approx y(t_n)$.

9.3 Méthode d'Euler explicite

Définition 9.2.

$$y_{n+1} = y_n + h f(t_n, y_n).$$

Algorithme 6 : Euler explicite

Entrée : f, t_0, T, y_0, h

Sortie : $(t_n, y_n)_{n=0}^N$

$N \leftarrow \lfloor (T - t_0)/h \rfloor$;

pour $n = 0, \dots, N - 1$ **faire**

$y_{n+1} \leftarrow y_n + h f(t_n, y_n)$;
 $t_{n+1} \leftarrow t_n + h$;

Théorème 9.3 (Erreur locale et globale d'Euler). • *Erreur locale de troncature* : $\tau_n = \frac{y(t_{n+1}) - y(t_n)}{h} - f(t_n, y(t_n)) = \mathcal{O}(h)$.

• *Erreur globale* : $\max_n |y(t_n) - y_n| = \mathcal{O}(h)$ (méthode d'ordre 1).

Esquisse. Par Taylor : $y(t_{n+1}) = y(t_n) + hy'(t_n) + \frac{h^2}{2}y''(\xi)$. Donc $\tau_n = \frac{h}{2}y''(\xi) = \mathcal{O}(h)$.
 L'erreur globale s'accumule sur $N = T/h$ pas : $e_N \leq \frac{e^{LT}-1}{L} \cdot \max |\tau_n| = \mathcal{O}(h)$. $\square$

9.4 Méthode d'Euler implicite

Définition 9.4.

$$y_{n+1} = y_n + h f(t_{n+1}, y_{n+1}).$$

Nécessite la résolution d'une équation (Newton) à chaque pas. Avantage : **A-stabilité**.

9.5 Méthodes de Runge–Kutta

Définition 9.5 (RK4 classique).

$$k_1 = f(t_n, y_n), \tag{9.1}$$

$$k_2 = f(t_n + h/2, y_n + hk_1/2), \tag{9.2}$$

$$k_3 = f(t_n + h/2, y_n + hk_2/2), \tag{9.3}$$

$$k_4 = f(t_n + h, y_n + hk_3), \tag{9.4}$$

$$y_{n+1} = y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \tag{9.5}$$

Théorème 9.6 (Ordre de RK4). *RK4 est d'ordre 4 : erreur globale $\mathcal{O}(h^4)$.*

9.6 Tableau de Butcher

Définition 9.7. Un schéma de Runge–Kutta à s étages est défini par :

$$\begin{array}{c|ccc}
 \mathbf{c} & A & & \\
 \hline
 & & \mathbf{b}^\top &
 \end{array}$$

Pour RK4 :


$$\begin{array}{c|ccc}
 0 & & & \\
 1/2 & 1/2 & & \\
 1/2 & 0 & 1/2 & \\
 1 & 0 & 0 & 1 \\
 \hline
 & 1/6 & 1/3 & 1/3 & 1/6
 \end{array}$$

9.7 Stabilité

Définition 9.8 (Équation test). $y' = \lambda y$, $\lambda \in \mathbb{C}$, $\operatorname{Re}(\lambda) < 0$. Le facteur d'amplification est $R(z)$ avec $z = h\lambda$: $y_{n+1} = R(z)y_n$.

- Euler explicite : $R(z) = 1 + z$. Stable si $|1 + z| < 1$.
- Euler implicite : $R(z) = 1/(1 - z)$. Stable pour tout $\operatorname{Re}(z) < 0$ (A-stable).
- RK4 : $R(z) = 1 + z + z^2/2 + z^3/6 + z^4/24$.

Région de stabilité d'Euler explicite



9.8 Exemple numérique

$y' = -y$, $y(0) = 1$, solution exacte $y = e^{-t}$.

h	Euler	Err. Euler	RK4	Err. RK4
0.1	0.348678	$1,9 \times 10^{-2}$	0.367879	$3,8 \times 10^{-8}$
0.05	0.358486	$9,4 \times 10^{-3}$	0.367879	$2,4 \times 10^{-9}$
0.01	0.366032	$1,8 \times 10^{-3}$	0.367879	$< 10^{-15}$

9.9 Implémentation

Python

<MINTED>

Julia

<MINTED>

9.10 Exercices

Exercice 9.1 (★). Appliquer Euler explicite à $y' = y$, $y(0) = 1$, $h = 0,1$, pour $t \in [0, 1]$. Comparer à e^t .

Exercice 9.2 (★★). Montrer que RK4 est d'ordre 4 en développant $y(t + h)$ par Taylor jusqu'au terme h^4 .

Exercice 9.3 (★★). Tracer la région de stabilité de RK4 numériquement.

Exercice 9.4 (★★★ – Projet). Résoudre le système de Lorenz ($\sigma = 10, \rho = 28, \beta = 8/3$) par RK4. Visualiser l'attracteur en 3D. Étudier la sensibilité aux conditions initiales.

Formules clés

$$\text{Euler : } y_{n+1} = y_n + hf(t_n, y_n), \quad \mathcal{O}(h)$$

$$\text{RK4 : } y_{n+1} = y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4), \quad \mathcal{O}(h^4)$$

$$\text{Stabilité : } |R(h\lambda)| < 1$$

Chapitre 10

Valeurs Propres et Vecteurs Propres

En 1998, deux doctorants de Stanford — Sergey Brin et Larry Page — modélisent le World Wide Web comme un graphe orienté de plusieurs millions de pages, et cherchent à classer chaque page par importance. Leur algorithme, baptisé PageRank, revient mathématiquement à calculer le vecteur propre dominant d’une matrice stochastique géante. Ils utilisent la méthode de la puissance, publiée par Richard von Mises en 1929 : on choisit un vecteur initial, on le multiplie par la matrice, on le normalise, et on recommence ; la suite converge vers le vecteur propre dominant. C’est ainsi que Google a démarré. Ce chapitre couvre les méthodes itératives modernes pour les valeurs propres : puissance, puissance inverse, itération de Rayleigh, algorithme QR — pierre angulaire de LAPACK — et les méthodes de Krylov (Lanczos, Arnoldi) qui dominent le calcul pour les matrices creuses.

10.1 Exemple motivant

L’analyse des vibrations d’une structure (pont, bâtiment) revient à trouver les fréquences propres, i.e. les valeurs propres d’une matrice de rigidité. Pour une matrice 1000×1000 , calculer le polynôme caractéristique est impraticable : on utilise des méthodes itératives.

10.2 Rappels

Définition 10.1. $\lambda \in \mathbb{C}$ est **valeur propre** de $A \in \mathbb{R}^{n \times n}$ s’il existe $x \neq 0$ tel que $Ax = \lambda x$. Le vecteur x est un **vecteur propre** associé. L’ensemble des valeurs propres est le **spectre** $\sigma(A)$.

Théorème 10.2 (Propriétés spectrales). • $\sigma(A) \subset \{z : |z| \leq \|A\|\}$ (*rayon spectral* $\rho(A) \leq \|A\|$).

- Si A est symétrique réelle, toutes ses valeurs propres sont réelles.
- Si A est symétrique définie positive, toutes ses valeurs propres sont strictement positives.
- Théorème de Gerschgorin : $\sigma(A) \subset \bigcup_{i=1}^n D(a_{ii}, R_i)$ où $R_i = \sum_{j \neq i} |a_{ij}|$.

10.3 Méthode de la puissance itérée

Définition 10.3. Pour trouver la valeur propre dominante λ_1 (celle de plus grand module) et le vecteur propre associé.

Algorithme 7 : Puissance itérée

Entrée : $A \in \mathbb{R}^{n \times n}$, $x^{(0)}$ vecteur initial, tolérance ε , $k_{\max}$
Sortie : λ_1 , x_1
pour $k = 1, 2, \dots, k_{\max}$ **faire**
 $w \leftarrow Ax^{(k-1)}$;
 $x^{(k)} \leftarrow w / \|w\|$;
 $\lambda^{(k)} \leftarrow (x^{(k)})^\top Ax^{(k)}$; // quotient de Rayleigh
 si $|\lambda^{(k)} - \lambda^{(k-1)}| < \varepsilon$ **alors**
 retourner $\lambda^{(k)}$, $x^{(k)}$;
fin

Théorème 10.4 (Convergence de la puissance itérée). Soit $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$. Si $x^{(0)}$ a une composante non nulle selon le vecteur propre associé à λ_1 , alors :

$$|\lambda^{(k)} - \lambda_1| = \mathcal{O}\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right).$$

La convergence est linéaire de rapport $|\lambda_2/\lambda_1|$.

Esquisse. Décomposons $x^{(0)} = \alpha_1 v_1 + \dots + \alpha_n v_n$ dans la base de vecteurs propres. Alors $A^k x^{(0)} = \alpha_1 \lambda_1^k \left[v_1 + \sum_{i \geq 2} \frac{\alpha_i}{\alpha_1} \left(\frac{\lambda_i}{\lambda_1} \right)^k v_i \right]$. Quand $k \rightarrow \infty$, le terme entre crochets tend vers v_1 . □

10.4 Méthode de la puissance inverse

Définition 10.5. Pour trouver la valeur propre la plus proche d'un **décalage** μ : on applique la puissance itérée à $(A - \mu I)^{-1}$, dont la valeur propre dominante est $1/(\lambda_{\min} - \mu)$.

Algorithme 8 : Puissance inverse avec décalage

Entrée : A , μ , $x^{(0)}$, ε , $k_{\max}$
Sortie : λ , x
Factoriser $A - \mu I = LU$;
pour $k = 1, 2, \dots, k_{\max}$ **faire**
 Résoudre $(A - \mu I)w = x^{(k-1)}$;
 $x^{(k)} \leftarrow w / \|w\|$;
 $\lambda^{(k)} \leftarrow (x^{(k)})^\top Ax^{(k)}$;
 si $|\lambda^{(k)} - \lambda^{(k-1)}| < \varepsilon$ **alors**
 retourner $\lambda^{(k)}$, $x^{(k)}$;
fin

Théorème 10.6. La puissance inverse avec décalage μ converge vers la valeur propre λ_j la plus proche de μ , avec un taux $|\lambda_j - \mu|/|\lambda_k - \mu|$ où λ_k est la deuxième plus proche.

10.5 Méthode QR

Définition 10.7 (Itération QR). À partir de $A_0 = A$:

1. Factoriser $A_k = Q_k R_k$ (factorisation QR).
2. Poser $A_{k+1} = R_k Q_k$.

A_k converge vers une matrice triangulaire supérieure (ou quasi-triangulaire) dont la diagonale contient les valeurs propres.

Algorithme 9 : Itération QR basique

Entrée : $A \in \mathbb{R}^{n \times n}$, $k_{\max}$

Sortie : Valeurs propres approchées

$A_0 \leftarrow A$;

pour $k = 0, 1, \dots, k_{\max} - 1$ **faire**

$Q_k R_k \leftarrow A_k$; // factorisation QR
 $A_{k+1} \leftarrow R_k Q_k$;

retourner $\text{diag}(A_{k_{\max}})$;

Théorème 10.8 (Convergence de l'algorithme QR). *Si A est réelle avec des valeurs propres de modules distincts $|\lambda_1| > |\lambda_2| > \dots > |\lambda_n| > 0$, alors A_k converge vers une matrice triangulaire supérieure. Les éléments sous-diagonaux satisfont :*

$$|(A_k)_{ij}| = \mathcal{O}\left(\left|\frac{\lambda_i}{\lambda_j}\right|^k\right), \quad i > j.$$

10.6 Améliorations pratiques

10.6.1 Réduction de Hessenberg

Définition 10.9. Avant l'itération QR, on réduit A en forme de Hessenberg supérieure ($h_{ij} = 0$ pour $i > j + 1$) par des transformations de Householder. Coût : $\frac{10}{3}n^3$ opérations. Chaque itération QR sur une matrice de Hessenberg coûte alors $\mathcal{O}(n^2)$ au lieu de $\mathcal{O}(n^3)$.

10.6.2 Décalage de Wilkinson

Définition 10.10. À chaque itération, on factorise $A_k - \mu_k I = Q_k R_k$ puis $A_{k+1} = R_k Q_k + \mu_k I$. Le décalage μ_k est la valeur propre de la sous-matrice 2×2 en bas à droite la plus proche de $a_{nn}^{(k)}$. Cela assure une convergence **cubique**.

10.7 Décomposition en valeurs singulières (SVD)

Définition 10.11. Pour toute matrice $A \in \mathbb{R}^{m \times n}$:

$$A = U \Sigma V^T,$$

où $U \in \mathbb{R}^{m \times m}$ et $V \in \mathbb{R}^{n \times n}$ sont orthogonales, $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$ avec $\sigma_1 \geq \dots \geq \sigma_p \geq 0$, $p = \min(m, n)$.

Théorème 10.12 (Propriétés de la SVD). • $\sigma_i = \sqrt{\lambda_i(A^\top A)}$.


- $\|A\|_2 = \sigma_1$, $\|A\|_F = \sqrt{\sum \sigma_i^2}$.
- $\text{cond}_2(A) = \sigma_1/\sigma_n$.
- $\text{rang}(A) = \text{nombre de } \sigma_i > 0$.
- Meilleure approximation de rang r : $A_r = \sum_{i=1}^r \sigma_i u_i v_i^\top$ (théorème d'Eckart-Young).

10.8 Disques de Gerschgorin

Théorème 10.13 (Gerschgorin). Toute valeur propre de A se trouve dans au moins un des disques :

$$D_i = \{z \in \mathbb{C} : |z - a_{ii}| \leq R_i\}, \quad R_i = \sum_{j \neq i} |a_{ij}|.$$

De plus, si l'union de k disques est disjointe des $n - k$ autres, elle contient exactement k valeurs propres.



10.9 Exemple numérique

$A = \begin{pmatrix} 4 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$, valeurs propres exactes : $\lambda \approx 5,049, 2,643, 1,307$.

Itération k	$\lambda_1^{(k)}$	$\lambda_2^{(k)}$	$\lambda_3^{(k)}$
0 (Puissance)	4.000	—	—
5	5.023	—	—
10	5.048	—	—
20	5.049	—	—
QR $k = 5$	5.049	2.644	1.307
QR $k = 10$	5.049	2.643	1.307

10.10 Implémentation

Python

<MINTED>

Julia

<MINTED>

10.11 Exercices

Exercice 10.1 (★). Appliquer la méthode de la puissance à $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ avec $x^{(0)} = (1, 1)^\top$. Calculer les 5 premières itérations.

Exercice 10.2 (★★). Montrer que l'itération QR préserve la similarité : $A_{k+1} = Q_k^\top A_k Q_k$.

Exercice 10.3 (★★). Tracer les disques de Gerschgorin pour $A = \begin{pmatrix} 5 & 1 & 0 \\ 1 & 3 & 0,5 \\ 0 & 0,5 & 1 \end{pmatrix}$ et localiser les valeurs propres.

Exercice 10.4 (★★★ – Projet). Implémenter l'algorithme QR avec réduction de Hessenberg et décalage de Wilkinson. Comparer les performances avec l'algorithme QR basique sur des matrices aléatoires de taille $n = 50, 100, 200$.

Formules clés

$$Ax = \lambda x, \quad \rho(A) = \max |\lambda_i|$$

$$\text{Puissance : } x^{(k)} = \frac{Ax^{(k-1)}}{\|Ax^{(k-1)}\|}, \quad \mathcal{O}(|\lambda_2/\lambda_1|^k)$$

$$\text{QR : } A_k = Q_k R_k, \quad A_{k+1} = R_k Q_k$$

$$\text{SVD : } A = U \Sigma V^\top, \quad \text{cond}_2(A) = \sigma_1/\sigma_n$$

Formulaire

.1 Normes vectorielles et matricielles

$$\|x\|_1 = \sum |x_i|, \quad \|x\|_2 = \sqrt{\sum x_i^2}, \quad \|x\|_\infty = \max |x_i| \quad (1)$$

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad \|A\|_\infty = \max_i \sum_j |a_{ij}|, \quad \|A\|_2 = \sigma_{\max}(A) \quad (2)$$

.2 Erreurs

$$\text{Erreur absolue : } |x - \tilde{x}| \quad (3)$$

$$\text{Erreur relative : } \frac{|x - \tilde{x}|}{|x|} \quad (4)$$

$$\text{Conditionnement : } \text{cond}(A) = \|A\| \cdot \|A^{-1}\| \quad (5)$$

.3 Quadratures

$$\text{Trapèzes : } \frac{h}{2}[f(a) + 2 \sum f(x_i) + f(b)], \quad E = \mathcal{O}(h^2) \quad (6)$$

$$\text{Simpson : } \frac{h}{3}[f(a) + 4 \sum f_{\text{imp}} + 2 \sum f_{\text{pair}} + f(b)], \quad E = \mathcal{O}(h^4) \quad (7)$$

.4 Méthodes pour EDO

$$\text{Euler explicite : } y_{n+1} = y_n + hf(t_n, y_n), \quad \mathcal{O}(h) \quad (8)$$

$$\text{RK4 : } y_{n+1} = y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4), \quad \mathcal{O}(h^4) \quad (9)$$

Bibliographie

- [1] QUARTERONI, A., Sacco, R. & Saleri, F. (2007). *Numerical Mathematics*. 2e éd., Springer.
- [2] SÜLI, E. & Mayers, D. (2003). *An Introduction to Numerical Analysis*. Cambridge University Press.
- [3] TREFETHEN, L.N. & Bau, D. (1997). *Numerical Linear Algebra*. SIAM.
- [4] HIGHAM, N.J. (2002). *Accuracy and Stability of Numerical Algorithms*. 2e éd., SIAM.
- [5] DEMAILLY, J.-P. (2006). *Analyse Numérique et Équations Différentielles*. EDP Sciences.