

Séries Temporelles

Notes de Cours

Yaé Ulrich Gaba

Master M1 — 2025–2026

Table des matières

Préface	vii
1 Introduction aux Séries Temporelles	1
1.1 Exemple motivant	1
1.2 Définitions fondamentales	1
1.3 Composantes d'une série temporelle	1
1.4 Opérateur retard et différence	2
1.5 Exemples de séries temporelles	2
1.6 Visualisation	2
1.7 Implémentation	3
1.8 Exercices	4
2 Stationnarité et Autocovariance	5
2.1 Exemple motivant	5
2.2 Stationnarité stricte et faible	5
2.3 Fonction d'autocovariance	6
2.4 Estimation de l'autocovariance	6
2.5 Autocorrélation partielle	7
2.6 Tests de stationnarité	7
2.7 Implémentation	7
2.8 Exercices	8
3 Modèles AR, MA, ARMA	9
3.1 Exemple motivant	9
3.2 Processus autorégressifs $AR(p)$	9
3.3 Équations de Yule–Walker	10
3.4 Processus moyenne mobile $MA(q)$	10

3.5	Processus ARMA(p, q)	11
3.6	Signatures ACF/PACF	11
3.7	Implémentation	11
3.8	Exercices	12
4	Identification, Estimation et Diagnostic	13
4.1	Exemple motivant	13
4.2	La méthodologie de Box–Jenkins	13
4.3	Identification	14
4.3.1	Examen de l'ACF et de la PACF	14
4.3.2	Critères d'information	14
4.4	Estimation	14
4.4.1	Maximum de vraisemblance	14
4.4.2	Moindres carrés conditionnels	15
4.5	Diagnostic	15
4.5.1	Analyse des résidus	15
4.6	Implémentation	15
4.7	Exercices	16
5	Modèles ARIMA et Différenciation	19
5.1	Exemple motivant	19
5.2	Processus intégrés	19
5.3	Modèle ARIMA(p, d, q)	19
5.4	SARIMA : saisonnalité	20
5.5	Stratégie de différenciation	20
5.6	Exemple numérique : AirPassengers	21
5.7	Implémentation	21
5.8	Exercices	22
6	Modèles GARCH et Volatilité Conditionnelle	23
6.1	Exemple motivant	23
6.2	Faits stylisés des rendements financiers	23
6.3	Modèle ARCH	24
6.4	Modèle GARCH	24

6.5	IGARCH	24
6.6	Extensions	25
6.6.1	EGARCH	25
6.6.2	GJR-GARCH	25
6.7	Estimation	25
6.8	Tests d'effet ARCH	25
6.9	Implémentation	25
6.10	Exercices	26
7	Analyse Spectrale	27
7.1	Exemple motivant	27
7.2	Densité spectrale	27
7.3	Spectres de processus classiques	28
7.4	Périodogramme	28
7.5	Estimation spectrale	29
7.5.1	Fenêtre spectrale (lissage)	29
7.5.2	Méthode paramétrique	29
7.6	Implémentation	29
7.7	Exercices	30
8	Modèles à Espace d'États et Filtre de Kalman	31
8.1	Exemple motivant	31
8.2	Modèle linéaire gaussien à espace d'états	31
8.3	Filtre de Kalman	32
8.4	Lisseur de Kalman	32
8.5	Vraisemblance par le filtre de Kalman	32
8.6	Implémentation	33
8.7	Exercices	34
9	Séries Temporelles Multivariées — VAR et Cointégration	35
9.1	Exemple motivant	35
9.2	Processus vectoriels stationnaires	35
9.3	Modèle VAR(p)	36
9.3.1	Estimation	36

9.4	Causalité de Granger	36
9.5	Fonctions de réponse impulsionnelle	36
9.6	Coïntégration	36
9.6.1	Test de Johansen	37
9.7	Implémentation	37
9.8	Exercices	38
10	Prévision et Intervalles de Confiance	39
10.1	Exemple motivant	39
10.2	Prévision optimale	39
10.3	Prévision ARMA	40
10.4	Intervalles de prévision	40
10.5	Prévision ARIMA	40
10.6	Critères d'évaluation	41
10.7	Test de Diebold–Mariano	41
10.8	Implémentation	41
10.9	Exercices	42
11	Applications : Finance, Économie, Météorologie	45
11.1	Exemple motivant	45
11.2	Finance : Modélisation de la volatilité	45
11.2.1	Valeur à risque (VaR)	45
11.2.2	Application	46
11.3	Économie : Prévision macroéconomique	46
11.3.1	PIB et indicateurs avancés	46
11.4	Météorologie : Températures et saisonnalité	47
11.5	Résumé méthodologique	48
11.6	Exercices	48
	Formulaire	51
.1	Processus ARMA	51
.2	Autocovariance et autocorrélation	51
.3	Critères d'information	51
.4	GARCH	51
.5	Filtre de Kalman	52
.6	VAR	52

Préface

Les données indexées par le temps sont omniprésentes : cours boursiers minute par minute, températures journalières, PIB trimestriel, signaux EEG, trafic réseau. L'**analyse des séries temporelles** fournit le cadre mathématique pour modéliser la *dépendance temporelle* inhérente à ces données, et exploiter cette structure pour la *prévision*, la *détection d'anomalies* et la *compréhension* des mécanismes sous-jacents.

Ce cours, destiné aux étudiants de Master en statistique, économie et science des données, couvre la théorie classique (processus ARMA, analyse spectrale, filtre de Kalman) et les développements modernes (GARCH, cointégration, modèles VAR). Chaque concept est illustré par des données réelles et accompagné d'implémentations en Python.

Prérequis. Probabilités (convergences, espérance conditionnelle), statistique mathématique (estimation, tests), analyse réelle, algèbre linéaire.

Références.

- BOX, Jenkins, Reinsel, Ljung — *Time Series Analysis : Forecasting and Control*, Wiley.
- BROCKWELL, Davis — *Introduction to Time Series and Forecasting*, Springer.
- HAMILTON — *Time Series Analysis*, Princeton University Press.
- SHUMWAY, Stoffer — *Time Series Analysis and Its Applications*, Springer.
- GOURIÉROUX, Monfort — *Séries Temporelles et Modèles Dynamiques*, Economica.

Chapitre 1

Introduction aux Séries Temporelles

1.1 Exemple motivant

Le cours de clôture journalier de l'indice CAC 40 de 2000 à 2024 présente une tendance, des cycles et une volatilité variable. Contrairement aux données iid, chaque observation dépend des précédentes. L'analyse des séries temporelles exploite cette dépendance.

1.2 Définitions fondamentales

Définition 1.1 (Série temporelle). Une **série temporelle** (ou **processus stochastique à temps discret**) est une suite de variables aléatoires $(X_t)_{t \in \mathbb{Z}}$ définies sur un espace de probabilité $(\Omega, \mathcal{F}, P)$. Une **réalisation** (ou trajectoire) est une suite observée $(x_1, \dots, x_n)$.

Définition 1.2 (Bruit blanc). Un **bruit blanc** (ε_t) est une suite de variables aléatoires telles que :

1. $\mathbb{E}[\varepsilon_t] = 0$ pour tout t ,
2. $\text{Var}(\varepsilon_t) = \sigma^2$ pour tout t ,
3. $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ pour $t \neq s$.

Notation : $\varepsilon_t \sim \text{BB}(0, \sigma^2)$. Si de plus les ε_t sont gaussiens, on parle de **bruit blanc gaussien**.

Définition 1.3 (Bruit blanc fort). Un **bruit blanc fort** est une suite iid de variables aléatoires de moyenne nulle et variance finie. Un bruit blanc (faible) n'impose que la décorrélation, pas l'indépendance.

1.3 Composantes d'une série temporelle

Définition 1.4 (Décomposition classique). On décompose souvent une série en :

$$X_t = T_t + S_t + R_t,$$

où T_t est la **tendance** (trend), S_t la **saisonnalité** (composante périodique) et R_t le **résidu** (composante aléatoire).

Modèle **multiplicatif** : $X_t = T_t \cdot S_t \cdot R_t$ (fréquent quand l'amplitude saisonnière croît avec le niveau).

1.4 Opérateur retard et différence

Définition 1.5 (Opérateur retard). L'**opérateur retard** B (ou *backshift operator*) est défini par :

$$BX_t = X_{t-1}, \quad B^k X_t = X_{t-k}.$$

L'**opérateur différence** est $\nabla = 1 - B$: $\nabla X_t = X_t - X_{t-1}$.

Remarque 1.6. On manipule les polynômes en B comme des polynômes ordinaires. Par exemple, $(1 - \phi B)X_t = \varepsilon_t$ s'écrit $X_t - \phi X_{t-1} = \varepsilon_t$.


1.5 Exemples de séries temporelles


Exemple 1.7 (Marche aléatoire). $X_t = X_{t-1} + \varepsilon_t$ avec $\varepsilon_t \sim \text{BB}(0, \sigma^2)$. Alors $X_t = X_0 + \sum_{i=1}^t \varepsilon_i$ et $\text{Var}(X_t) = t\sigma^2 \rightarrow \infty$: la marche aléatoire n'est **pas stationnaire**.

Exemple 1.8 (Tendance linéaire + bruit). $X_t = a + bt + \varepsilon_t$. Pas stationnaire (la moyenne $\mathbb{E}[X_t] = a + bt$ dépend de t).

Exemple 1.9 (Série saisonnière). Températures mensuelles : période $s = 12$. On modélise S_t par des fonctions trigonométriques ou des indicatrices mensuelles.

1.6 Visualisation





1.7 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Simuler une marche aléatoire
np.random.seed(42)
n = 500
eps = np.random.normal(0, 1, n)
rw = np.cumsum(eps)

# Simuler un AR(1)
phi = 0.8
ar1 = np.zeros(n)
for t in range(1, n):
    ar1[t] = phi * ar1[t-1] + eps[t]

# Charger des données réelles (exemple : AirPassengers)
# url =
# ↪ 'https://raw.githubusercontent.com/jbrownlee/Datasets/master/airline-passengers.csv'
# df = pd.read_csv(url, parse_dates=['Month'], index_col='Month')

fig, axes = plt.subplots(2, 1, figsize=(12, 6))
axes[0].plot(rw, lw=0.8)
axes[0].set_title('Marche aléatoire')
axes[0].set_xlabel('t')

axes[1].plot(ar1, lw=0.8, color='red')
axes[1].set_title('AR(1) avec  $\phi=0.8$ ')
axes[1].set_xlabel('t')

plt.tight_layout()
plt.savefig('ch01_intro.pdf')
```

```
plt.show()
```

1.8 Exercices

Exercice 1.1 (★). Simuler 1000 réalisations d’une marche aléatoire de longueur $n = 200$. Tracer 10 trajectoires sur le même graphique. Calculer la variance empirique de X_{200} .

Exercice 1.2 (★). Charger la série `AirPassengers`. Identifier visuellement la tendance, la saisonnalité et la volatilité croissante. Proposer un modèle additif ou multiplicatif.

Exercice 1.3 (★★). Montrer que si $X_t = X_{t-1} + \varepsilon_t$ (marche aléatoire), alors $\text{Var}(X_t) = t\sigma^2$ et $\text{Corr}(X_t, X_s) = \sqrt{\min(t, s) / \max(t, s)}$ pour $t, s > 0$.

Exercice 1.4 (★★★ – Projet). Télécharger les cours journaliers d’une action (ex. Apple) sur 5 ans. Décomposer la série en tendance, saisonnalité et résidu. Calculer les log-rendements $r_t = \ln(P_t/P_{t-1})$ et analyser leurs propriétés statistiques.

Formules clés

$$BX_t = X_{t-1}, \quad \nabla X_t = X_t - X_{t-1}$$

$$X_t = T_t + S_t + R_t \quad (\text{décomposition additive})$$

$$\text{Marche aléatoire : } X_t = X_{t-1} + \varepsilon_t, \quad \text{Var}(X_t) = t\sigma^2$$

Chapitre 2

Stationnarité et Autocovariance

En 1927, le statisticien britannique George Udny Yule publie dans *Philosophical Transactions* une analyse des relevés annuels du nombre de taches solaires depuis 1749 — une série temporelle de cent soixante-quinze ans avec une oscillation pseudo-périodique d'environ onze ans. Yule cherche à expliquer pourquoi cette série, contrairement à une fonction sinusoïdale pure, présente des variations d'amplitude et de phase. Sa réponse fonde la théorie moderne des séries temporelles : modéliser non pas une oscillation déterministe, mais une équation aux différences stochastique — ce qui deviendra l'*autoregression*. Pour que cette analyse soit possible, il faut postuler que les propriétés statistiques de la série ne changent pas dans le temps : la stationnarité. Ce chapitre formalise la stationnarité (stricte vs faible), introduit les fonctions d'autocovariance et d'autocorrélation, présente les opérateurs de retard et le test ADF pour la stationnarité, et discute des transformations (différenciation, log-transformation) qui rendent stationnaires des séries qui ne le sont pas.

2.1 Exemple motivant

La température journalière à Paris sur 30 ans présente une saisonnalité marquée mais, après désaisonnalisation, les résidus semblent fluctuer autour d'une moyenne constante avec une structure de dépendance invariante. C'est la **stationnarité**.

2.2 Stationnarité stricte et faible

Définition 2.1 (Stationnarité stricte). (X_t) est **strictement stationnaire** si pour tout $k \geq 1$, tout $(t_1, \dots, t_k)$ et tout $h \in \mathbb{Z}$:

$$(X_{t_1}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_k+h}).$$

Définition 2.2 (Stationnarité faible (au second ordre)). (X_t) est **faiblement stationnaire** (ou stationnaire au sens large) si :

1. $\mathbb{E}[X_t^2] < \infty$ pour tout t ,

2. $\mu = \mathbb{E}[X_t]$ ne dépend pas de t ,
3. $\gamma(t, t+h) = \text{Cov}(X_t, X_{t+h})$ ne dépend que de h .

Remarque 2.3. Stationnarité stricte + moments d'ordre 2 finis $\Rightarrow$ stationnarité faible. La réciproque est fausse en général, mais vraie pour les processus gaussiens.

2.3 Fonction d'autocovariance

Définition 2.4 (Autocovariance et autocorrélation). Pour un processus faiblement stationnaire :

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \mathbb{E}[(X_t - \mu)(X_{t+h} - \mu)], \quad (2.1)$$

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \text{Corr}(X_t, X_{t+h}). \quad (2.2)$$

La fonction $\rho(\cdot)$ est la **fonction d'autocorrélation** (ACF).

Théorème 2.5 (Propriétés de γ). 1. $\gamma(0) \geq 0$ (c'est la variance).

2. $\gamma(h) = \gamma(-h)$ (symétrie).

3. $|\gamma(h)| \leq \gamma(0)$ (par Cauchy-Schwarz).

4. γ est **semi-définie positive** : pour tout n , tout $(a_1, \dots, a_n) \in \mathbb{R}^n$ et tout $(t_1, \dots, t_n)$:

$$\sum_{i,j} a_i a_j \gamma(t_i - t_j) \geq 0.$$

Démonstration. (4) : $\sum_{i,j} a_i a_j \gamma(t_i - t_j) = \text{Var}(\sum_i a_i X_{t_i}) \geq 0.$ □

Théorème 2.6 (Herglotz). $\gamma : \mathbb{Z} \rightarrow \mathbb{R}$ est une fonction d'autocovariance si et seulement si elle est semi-définie positive. De plus, il existe une mesure positive finie F sur $[-\pi, \pi]$ (mesure spectrale) telle que :

$$\gamma(h) = \int_{-\pi}^{\pi} e^{i\omega h} dF(\omega).$$

2.4 Estimation de l'autocovariance

Définition 2.7 (Autocovariance empirique).

$$\hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-|h|} (X_t - \bar{X})(X_{t+|h|} - \bar{X}), \quad \hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}.$$

On divise par n (et non $n - |h|$) pour garantir que la matrice $(\hat{\gamma}(i - j))$ est semi-définie positive.

Théorème 2.8 (Bartlett). Pour un bruit blanc de taille n : $\hat{\rho}(h) \stackrel{\text{approx}}{\sim} \mathcal{N}(0, 1/n)$ pour $h \geq 1$. Les **bandes de Bartlett** $\pm 1,96/\sqrt{n}$ servent à tester si $\rho(h) = 0$.

2.5 Autocorrélation partielle

Définition 2.9 (PACF). L'autocorrélation partielle au décalage h est :

$$\alpha(h) = \text{Corr}(X_t - \hat{X}_t, X_{t+h} - \hat{X}_{t+h}),$$

où $\hat{X}_t$ et $\hat{X}_{t+h}$ sont les projections linéaires sur $(X_{t+1}, \dots, X_{t+h-1})$.

Équivalamment, $\alpha(h)$ est le dernier coefficient ϕ_{hh} dans la régression linéaire de X_t sur $(X_{t-1}, \dots, X_{t-h})$.

Théorème 2.10. Pour un $AR(p)$: $\alpha(h) = 0$ pour $h > p$. C'est l'outil principal pour identifier l'ordre p .

2.6 Tests de stationnarité

Définition 2.11 (Test de Dickey–Fuller augmenté (ADF)). Pour tester la présence d'une racine unitaire dans $X_t = \phi X_{t-1} + \varepsilon_t$:

$$H_0 : \phi = 1 \quad (\text{non stationnaire}) \quad \text{vs} \quad H_1 : |\phi| < 1 \quad (\text{stationnaire}).$$

On estime $\nabla X_t = (\phi - 1)X_{t-1} + \varepsilon_t$ et on teste si $\phi - 1 < 0$.

Attention

La distribution de la statistique ADF n'est **pas** gaussienne sous H_0 . On utilise les tables de Dickey–Fuller (ou les valeurs critiques calculées par simulation).

2.7 Implémentation

Python

```
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import acf, pacf, adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

# Simuler un AR(1)
np.random.seed(0)
n = 500
phi = 0.7
eps = np.random.normal(0, 1, n)
x = np.zeros(n)
for t in range(1, n):
    x[t] = phi * x[t-1] + eps[t]

# ACF et PACF
```

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(x, lags=30, ax=axes[0], title='ACF')
plot_pacf(x, lags=30, ax=axes[1], title='PACF')
plt.tight_layout()
plt.savefig('ch02_acf_pacf.pdf')
plt.show()

# Test ADF
result = adfuller(x, regression='c')
print(f"ADF statistic: {result[0]:.4f}")
print(f"p-value: {result[1]:.4f}")
print(f"Stationnaire: {result[1] < 0.05}")

# Marche aléatoire (non stationnaire)
rw = np.cumsum(eps)
result_rw = adfuller(rw, regression='c')
print(f"\nMarche aléatoire - ADF: {result_rw[0]:.4f},
↪ p={result_rw[1]:.4f}")
```

2.8 Exercices

Exercice 2.1 (*). Calculer la fonction d'autocovariance d'un bruit blanc $\varepsilon_t \sim \text{BB}(0, \sigma^2)$.

Exercice 2.2 (*). Calculer l'ACF de $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$ (MA(1)). Montrer que $\rho(h) = 0$ pour $|h| \geq 2$.

Exercice 2.3 (**). Montrer que si (X_t) est strictement stationnaire avec $\mathbb{E}[X_t^2] < \infty$, alors (X_t) est faiblement stationnaire.

Exercice 2.4 (**). Démontrer que l'autocovariance empirique $\hat{\gamma}(h)$ (divisée par n) donne une matrice de Toeplitz semi-définie positive.

Exercice 2.5 (***) – Projet). Appliquer le test ADF et le test KPSS à 10 séries économiques (PIB, chômage, inflation, etc.). Comparer les conclusions et discuter les cas de désaccord.

Formules clés

$$\begin{aligned}\gamma(h) &= \text{Cov}(X_t, X_{t+h}), \quad \rho(h) = \gamma(h)/\gamma(0) \\ \hat{\rho}(h) &\overset{\text{approx}}{\sim} \mathcal{N}(0, 1/n) \quad \text{sous } H_0 : \rho(h) = 0 \\ \text{ADF} : \nabla X_t &= (\phi - 1)X_{t-1} + \varepsilon_t, \quad H_0 : \phi = 1\end{aligned}$$

Chapitre 3

Modèles AR, MA, ARMA

En 1970, George E. P. Box et Gwilym M. Jenkins publient *Time Series Analysis : Forecasting and Control*, un ouvrage qui définit pour quarante ans la méthodologie standard de l'analyse de séries temporelles : une démarche en trois étapes — identification du modèle, estimation des paramètres, vérification des résidus — appliquée à la famille des modèles autorégressifs à moyenne mobile (ARMA). Box et Jenkins ne se contentent pas de définir les modèles : ils fournissent un protocole opérationnel utilisable par un ingénieur ou un économètre. L'approche est devenue si dominante qu'on parle aujourd'hui simplement de la *méthode Box-Jenkins*. Ce chapitre construit les processus $AR(p)$, $MA(q)$ et $ARMA(p, q)$, démontre les conditions de stationnarité et d'inversibilité, calcule les fonctions d'autocorrélation et d'autocorrélation partielle utilisées pour l'identification, et présente l'estimation par maximum de vraisemblance via le filtre de Kalman ou par moments de Yule-Walker.

3.1 Exemple motivant

Les log-rendements journaliers du CAC 40 montrent une corrélation faible mais significative aux premiers décalages. Un modèle $AR(1)$ ou $ARMA(1,1)$ capture cette dépendance linéaire.

3.2 Processus autorégressifs $AR(p)$

Définition 3.1 ($AR(p)$).

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t,$$

où $\varepsilon_t \sim \text{BB}(0, \sigma^2)$. En notation opérateur : $\phi(B)X_t = \varepsilon_t$ avec $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$.

Théorème 3.2 (Stationnarité d'un $AR(p)$). *L' $AR(p)$ admet une unique solution stationnaire si et seulement si toutes les racines de $\phi(z) = 0$ sont **en dehors du disque unité** : $|z_i| > 1$ pour tout i .*

Esquisse pour AR(1). $X_t = \phi X_{t-1} + \varepsilon_t$. Par récurrence : $X_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$. Cette série converge dans L^2 ssi $\sum \phi^{2j} < \infty$, i.e. $|\phi| < 1$. La racine de $\phi(z) = 1 - \phi z$ est $z = 1/\phi$, qui est hors du disque ssi $|\phi| < 1$. $\square$

Théorème 3.3 (ACF d'un AR(1)). Si $X_t = \phi X_{t-1} + \varepsilon_t$ avec $|\phi| < 1$:

$$\gamma(h) = \frac{\sigma^2 \phi^{|h|}}{1 - \phi^2}, \quad \rho(h) = \phi^{|h|}.$$

L'ACF décroît exponentiellement.

Démonstration. $\gamma(h) = \mathbb{E}[X_t X_{t+h}] = \phi \gamma(h-1)$ pour $h \geq 1$ (par multiplication de l'équation AR par X_{t+h} et prise d'espérance). Avec $\gamma(0) = \sigma^2/(1 - \phi^2)$. $\square$

Théorème 3.4 (PACF d'un AR(p)). Pour un AR(p) : $\alpha(h) = 0$ pour tout $h > p$. La PACF tronque à l'ordre p .

3.3 Équations de Yule–Walker

Définition 3.5. Pour un AR(p) stationnaire, les relations :

$$\gamma(h) = \phi_1 \gamma(h-1) + \dots + \phi_p \gamma(h-p) \quad (h \geq 1)$$

donnent le système de **Yule–Walker** :

$$\begin{pmatrix} \gamma(0) & \gamma(1) & \dots & \gamma(p-1) \\ \gamma(1) & \gamma(0) & \dots & \gamma(p-2) \\ \vdots & & \ddots & \vdots \\ \gamma(p-1) & \gamma(p-2) & \dots & \gamma(0) \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \gamma(1) \\ \gamma(2) \\ \vdots \\ \gamma(p) \end{pmatrix}.$$

3.4 Processus moyenne mobile MA(q)

Définition 3.6 (MA(q)).

$$X_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} = \theta(B) \varepsilon_t,$$

où $\theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$.

Théorème 3.7 (Stationnarité d'un MA(q)). Tout MA(q) est **toujours stationnaire** (somme finie de bruits blancs).

Théorème 3.8 (ACF d'un MA(q)).

$$\gamma(h) = \begin{cases} \sigma^2 \sum_{j=0}^{q-|h|} \theta_j \theta_{j+|h|} & \text{si } |h| \leq q, \\ 0 & \text{si } |h| > q, \end{cases}$$

avec $\theta_0 = 1$. L'ACF **tronque** au décalage q .

Définition 3.9 (Inversibilité). Un MA(q) est **inversible** si toutes les racines de $\theta(z) = 0$ sont en dehors du disque unité. Dans ce cas, X_t admet une représentation AR(∞) : $\pi(B)X_t = \varepsilon_t$ avec $\pi(z) = \theta(z)^{-1}$.

3.5 Processus ARMA(p, q)

Définition 3.10 (ARMA(p, q)).

$$\phi(B)X_t = \theta(B)\varepsilon_t, \quad \text{i.e.} \quad X_t - \sum_{i=1}^p \phi_i X_{t-i} = \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Théorème 3.11 (Conditions de stationnarité et inversibilité). • *Stationnaire* $\iff$ racines de $\phi(z) = 0$ hors du disque unité.

- *Inversible* $\iff$ racines de $\theta(z) = 0$ hors du disque unité.
- On exige toujours que $\phi(z)$ et $\theta(z)$ n'aient **pas de racine commune** (sinon le modèle est sur-paramétré).

Théorème 3.12 (Représentation MA(∞)). Si l'ARMA(p, q) est stationnaire : $X_t = \psi(B)\varepsilon_t$ avec $\psi(z) = \theta(z)/\phi(z) = \sum_{j=0}^{\infty} \psi_j z^j$. Les ψ_j sont les **poids de la réponse impulsionnelle**.

3.6 Signatures ACF/PACF

Modèle	ACF	PACF
AR(p)	Décroissance exponentielle/sinusoïdale	Tronque après p
MA(q)	Tronque après q	Décroissance exponentielle/sinusoïdale
ARMA(p, q)	Décroissance après q	Décroissance après p

3.7 Implémentation

Python

```
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.arima_process import ArmaProcess
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

# Simuler un AR(2)
np.random.seed(42)
ar_params = np.array([1, -0.75, 0.25]) # 1 - 0.75*B + 0.25*B^2
ma_params = np.array([1])
ar2 = ArmaProcess(ar_params, ma_params)
x = ar2.generate_sample(nsamples=500)

fig, axes = plt.subplots(1, 3, figsize=(15, 4))
axes[0].plot(x, lw=0.7)
axes[0].set_title('AR(2): $\phi_1=0.75, \phi_2=-0.25$')
```

```

plot_acf(x, lags=25, ax=axes[1], title='ACF')
plot_pacf(x, lags=25, ax=axes[2], title='PACF')
plt.tight_layout()
plt.savefig('ch03_arma.pdf')
plt.show()

# Simuler un MA(2)
ma_params = np.array([1, 0.6, -0.3])
ma2 = ArmaProcess(np.array([1]), ma_params)
y = ma2.generate_sample(nsample=500)

# Simuler un ARMA(1,1)
arma11 = ArmaProcess(np.array([1, -0.8]), np.array([1, 0.4]))
z = arma11.generate_sample(nsample=500)

# Yule-Walker
from statsmodels.regression.linear_model import yule_walker
rho, sigma = yule_walker(x, order=2)
print(f"Yule-Walker: phi = {rho}")

```

3.8 Exercices

Exercice 3.1 (*). Calculer l'ACF d'un MA(1) : $X_t = \varepsilon_t + 0,5\varepsilon_{t-1}$. Vérifier numériquement.

Exercice 3.2 (**). Montrer que l'AR(1) $X_t = \phi X_{t-1} + \varepsilon_t$ avec $|\phi| < 1$ a une représentation MA(∞) : $X_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$.

Exercice 3.3 (**). Montrer qu'un ARMA(1,1) avec $\phi = \theta$ se réduit à un bruit blanc (racine commune).

Exercice 3.4 (**). Dériver les équations de Yule-Walker pour un AR(2) et résoudre le système.

Exercice 3.5 (***) – Projet). Simuler des processus AR(1), AR(2), MA(1), MA(2), ARMA(1,1) et ARMA(2,1). Pour chacun, tracer l'ACF et la PACF théoriques et empiriques. Construire un guide visuel d'identification.

Formules clés

$\text{AR}(p) : \phi(B)X_t = \varepsilon_t$, stationnaire ssi racines de $\phi(z)$ hors disque
 $\text{MA}(q) : X_t = \theta(B)\varepsilon_t$, toujours stationnaire
ACF AR(1) : $\rho(h) = \phi^{|h|}$
ACF MA(q) : $\rho(h) = 0$ pour $|h| > q$

Chapitre 4

Identification, Estimation et Diagnostic

En 1974, Hirotugu Akaike, statisticien à l'Institut des Mathématiques Statistiques de Tokyo, publie un article qui résout définitivement le problème de la sélection de modèle pour les séries temporelles : le critère d'information d'Akaike (AIC), $AIC = -2 \ln \hat{L} + 2k$, pénalise la log-vraisemblance maximisée par le nombre de paramètres et fournit un compromis explicite entre ajustement et parcimonie. Le critère AIC, et son cousin BIC de Schwarz (1978), ont depuis envahi toute la statistique computationnelle. Pour les séries temporelles, ils permettent de choisir automatiquement les ordres (p, q) d'un ARMA, le degré de différenciation d d'un ARIMA, et la structure saisonnière des SARIMA. Ce chapitre construit la procédure d'identification de Box-Jenkins (lecture des ACF/PACF, sélection par AIC/BIC), présente l'estimation par MLE, et termine par les diagnostics résiduels (test de Ljung-Box pour l'absence d'autocorrélation, test de normalité de Jarque-Bera).

4.1 Exemple motivant

Face à une série temporelle réelle, comment choisir les ordres p et q d'un $ARMA(p, q)$, estimer les paramètres et vérifier que le modèle est adéquat ? C'est la **méthodologie de Box-Jenkins**.

4.2 La méthodologie de Box-Jenkins

Méthode

1. **Identification** : examiner l'ACF et la PACF pour proposer des ordres (p, q) .
2. **Estimation** : estimer $(\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \sigma^2)$ par maximum de vraisemblance ou moindres carrés conditionnels.
3. **Diagnostic** : vérifier que les résidus sont un bruit blanc.

4. **Prévision** : utiliser le modèle validé pour prévoir.

4.3 Identification

4.3.1 Examen de l'ACF et de la PACF

Règles pratiques (récapitulées au chapitre 3) :

- ACF tronque à $q \Rightarrow \text{MA}(q)$.
- PACF tronque à $p \Rightarrow \text{AR}(p)$.
- Les deux décroissent $\Rightarrow \text{ARMA}(p, q)$.

4.3.2 Critères d'information

Définition 4.1 (AIC et BIC).

$$\text{AIC}(p, q) = -2 \ln L(\hat{\theta}) + 2(p + q + 1), \quad (4.1)$$

$$\text{BIC}(p, q) = -2 \ln L(\hat{\theta}) + (p + q + 1) \ln n. \quad (4.2)$$

On choisit le modèle qui **minimise** le critère. Le BIC pénalise davantage la complexité.

Théorème 4.2 (Propriétés asymptotiques). • *L'AIC est asymptotiquement équivalent à la validation croisée leave-one-out.*

- *Le BIC est **consistant** : il sélectionne le vrai modèle avec probabilité $\rightarrow 1$.*
- *L'AIC tend à sur-paramétrer.*

4.4 Estimation

4.4.1 Maximum de vraisemblance

Définition 4.3. Pour un $\text{ARMA}(p, q)$ gaussien, la log-vraisemblance exacte est :

$$\ln L(\theta) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^n \ln v_t - \frac{1}{2} \sum_{t=1}^n \frac{e_t^2}{v_t},$$

où $e_t = X_t - \hat{X}_{t|t-1}$ est l'erreur de prévision un pas en avant et $v_t = \text{Var}(e_t)$, calculés récursivement (algorithme des innovations ou filtre de Kalman).

Théorème 4.4 (Propriétés de l'EMV). *Sous des conditions de régularité, l'EMV $\hat{\theta}_n$ est :*

- *Consistant : $\hat{\theta}_n \xrightarrow{P} \theta_0$.*
- *Asymptotiquement normal : $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, I(\theta_0)^{-1})$.*
- *Asymptotiquement efficace.*

4.4.2 Moindres carrés conditionnels

Définition 4.5. En conditionnant sur les premières observations, on minimise :

$$S(\theta) = \sum_{t=p+1}^n (X_t - \phi_1 X_{t-1} - \cdots - \phi_p X_{t-p} - \theta_1 \hat{\varepsilon}_{t-1} - \cdots - \theta_q \hat{\varepsilon}_{t-q})^2.$$

4.5 Diagnostic

4.5.1 Analyse des résidus

Définition 4.6. Les résidus du modèle sont $\hat{\varepsilon}_t = X_t - \hat{X}_{t|t-1}$. Si le modèle est correct, les $\hat{\varepsilon}_t$ doivent se comporter comme un bruit blanc.

Vérifications :

1. **ACF des résidus** : aucune autocorrélation significative.
2. **Test de Ljung–Box** :

$$Q(m) = n(n+2) \sum_{h=1}^m \frac{\hat{\rho}_{\hat{\varepsilon}}(h)^2}{n-h} \stackrel{H_0}{\sim} \chi^2(m-p-q).$$

3. **Normalité** : QQ-plot, test de Jarque–Bera.
4. **Hétéroscédasticité** : effet ARCH (cf. chapitre 6).

Théorème 4.7 (Ljung–Box). *Sous H_0 (résidus = bruit blanc), $Q(m) \sim \chi^2(m-p-q)$ asymptotiquement. On rejette H_0 si $Q(m) > \chi_{1-\alpha}^2(m-p-q)$.*

4.6 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.stats.diagnostic import acorr_ljungbox
from statsmodels.graphics.tsaplots import plot_acf

# Simuler un ARMA(1,1) connu
np.random.seed(42)
from statsmodels.tsa.arima_process import ArmaProcess
true_ar = np.array([1, -0.7])
true_ma = np.array([1, 0.3])
```

```

process = ArmaProcess(true_ar, true_ma)
data = process.generate_sample(nsample=500)

# Étape 1 : Identification (ACF/PACF déjà examinée)

# Étape 2 : Estimation par MLE
model = ARIMA(data, order=(1, 0, 1))
results = model.fit()
print(results.summary())
print(f"\nphi_1 = {results.arparams[0]:.4f} (vrai: 0.7)")
print(f"theta_1 = {results.maparams[0]:.4f} (vrai: 0.3)")

# Étape 3 : Diagnostic
residuals = results.resid

fig, axes = plt.subplots(2, 2, figsize=(12, 8))
axes[0,0].plot(residuals, lw=0.5)
axes[0,0].set_title('Résidus')
plot_acf(residuals, lags=25, ax=axes[0,1], title='ACF des résidus')
axes[1,0].hist(residuals, bins=30, density=True, alpha=0.7)
axes[1,0].set_title('Distribution des résidus')
from scipy import stats
stats.probplot(residuals, dist='norm', plot=axes[1,1])
axes[1,1].set_title('QQ-plot')
plt.tight_layout()
plt.savefig('ch04_diagnostic.pdf')
plt.show()

# Test de Ljung-Box
lb_test = acorr_ljungbox(residuals, lags=20, return_df=True)
print(lb_test)

# Sélection par AIC/BIC
results_table = []
for p in range(4):
    for q in range(4):
        try:
            m = ARIMA(data, order=(p, 0, q)).fit()
            results_table.append({'p': p, 'q': q,
                                'AIC': m.aic, 'BIC': m.bic})
        except:
            pass
df = pd.DataFrame(results_table).sort_values('BIC')
print(df.head(5))

```

4.7 Exercices

Exercice 4.1 (*). Simuler un AR(2) et appliquer la méthodologie complète : identification, estimation, diagnostic.

Exercice 4.2 (★★). Montrer que le test de Ljung–Box avec m décalages suit asymptotiquement une $\chi^2(m - p - q)$ sous H_0 .

Exercice 4.3 (★★). Comparer AIC et BIC sur 1000 simulations d'un AR(1). Lequel sélectionne le bon ordre le plus souvent ? Le BIC sur-pénalise-t-il en petit échantillon ?

Exercice 4.4 (★★★ – Projet). Appliquer la méthodologie Box–Jenkins complète à la série du taux de chômage mensuel français. Présenter chaque étape avec justification.

Formules clés

$$\begin{aligned} \text{AIC} &= -2 \ln L + 2k, & \text{BIC} &= -2 \ln L + k \ln n \\ Q(m) &= n(n+2) \sum_{h=1}^m \frac{\hat{\rho}_{\hat{\varepsilon}}(h)^2}{n-h} \sim \chi^2(m - p - q) \end{aligned}$$

Chapitre 5

Modèles ARIMA et Différenciation

En 1949, Pan American World Airways commande à un statisticien anglais, John Brown, une étude sur les passagers internationaux mensuels — un jeu de données de 144 observations qui deviendra le *airline data* célèbre de Box et Jenkins (*Series G* dans leur manuel). La série présente une tendance croissante, une saisonnalité annuelle marquée, et une augmentation de la variance proportionnelle au niveau. Aucun ARMA stationnaire ne peut s’y ajuster directement. La solution de Box et Jenkins consiste à *rendre* la série stationnaire par différenciation (pour la tendance) et par différenciation saisonnière (pour la périodicité), puis à appliquer ARMA. C’est la naissance du modèle ARIMA et de sa variante saisonnière SARIMA. Ce chapitre construit les ARIMA(p, d, q) et SARIMA(p, d, q) $\times$ (P, D, Q) $_s$, présente les tests de racine unitaire (ADF, KPSS, Phillips-Perron), démontre la prévision optimale et les intervalles de confiance, et termine par les ARFIMA fractionnaires pour les séries à longue mémoire.

5.1 Exemple motivant

Le PIB trimestriel français présente une tendance croissante : il n’est pas stationnaire. Après une différenciation ($\nabla X_t = X_t - X_{t-1}$), le taux de croissance est approximativement stationnaire et modélisable par un ARMA.

5.2 Processus intégrés

Définition 5.1 (Processus intégré d’ordre d). (X_t) est **intégré d’ordre d** , noté $X_t \sim I(d)$, si $\nabla^d X_t = (1 - B)^d X_t$ est stationnaire mais $\nabla^{d-1} X_t$ ne l’est pas.

Exemple 5.2. La marche aléatoire $X_t = X_{t-1} + \varepsilon_t$ est $I(1)$ car $\nabla X_t = \varepsilon_t$ est stationnaire.

5.3 Modèle ARIMA(p, d, q)

Définition 5.3 (ARIMA(p, d, q)).

$$\phi(B)(1 - B)^d X_t = \theta(B)\varepsilon_t.$$

X_t suit un $\text{ARIMA}(p, d, q)$ si $W_t = \nabla^d X_t$ suit un $\text{ARMA}(p, q)$.

Attention

On différencie pour rendre stationnaire, mais **trop différencier** (d trop grand) introduit des racines MA proches du cercle unité, ce qui dégrade les prévisions. En pratique, $d \leq 2$.

5.4 SARIMA : saisonnalité

Définition 5.4 ($\text{SARIMA}(p, d, q) \times (P, D, Q)_s$). Pour une série de période s :

$$\Phi(B^s)\phi(B)(1-B)^d(1-B^s)^D X_t = \Theta(B^s)\theta(B)\varepsilon_t,$$

où Φ, Θ sont les polynômes saisonniers d'ordres P, Q .

Exemple 5.5 (Airline model). Le modèle de Box–Jenkins pour AirPassengers est un $\text{SARIMA}(0, 1, 1) \times (0, 1, 1)_{12}$:


$$(1-B)(1-B^{12})X_t = (1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t.$$

5.5 Stratégie de différenciation

Méthode

1. Tracer la série et son ACF. Si l'ACF décroît très lentement, différencier.
2. Appliquer le test ADF (ou KPSS). Si H_0 (racine unitaire) n'est pas rejetée, différencier.
3. Après différenciation, vérifier que la série résultante est stationnaire.
4. Pour la saisonnalité, différencier à l'ordre s si l'ACF montre des pics périodiques.

5.6 Exemple numérique : AirPassengers



5.7 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import pmdarima as pm

# Charger AirPassengers
url = ('https://raw.githubusercontent.com/jbrownlee/Datasets/'
      'master/airline-passengers.csv')
df = pd.read_csv(url, parse_dates=['Month'], index_col='Month')
y = df['Passengers']

# Log-transformation (stabilise la variance)
y_log = np.log(y)

# Test ADF
print("ADF sur log(y):", adfuller(y_log)[1]) # > 0.05 => non stat.
y_diff = y_log.diff().dropna()
print("ADF sur diff(log(y)):", adfuller(y_diff)[1]) # < 0.05 => stat.

# SARIMA automatique
auto_model = pm.auto_arima(y_log, seasonal=True, m=12,
                           stepwise=True, trace=True)
print(auto_model.summary())

# Ajustement SARIMA(0,1,1)(0,1,1)[12]
model = SARIMAX(y_log, order=(0,1,1),
```

```

seasonal_order=(0,1,1,12))
results = model.fit(dispatch=False)
print(results.summary())

# Pr vision
forecast = results.get_forecast(steps=24)
pred = np.exp(forecast.predicted_mean)
ci = np.exp(forecast.conf_int())

fig, ax = plt.subplots(figsize=(12, 5))
y.plot(ax=ax, label='Observ ')
pred.plot(ax=ax, label='Pr vision', color='red')
ax.fill_between(ci.index, ci.iloc[:,0], ci.iloc[:,1],
               alpha=0.2, color='red')
ax.legend()
ax.set_title('SARIMA - AirPassengers')
plt.savefig('ch05_arima.pdf')
plt.show()

```

5.8 Exercices

Exercice 5.1 (*). Montrer que $(1 - B)^2 X_t = X_t - 2X_{t-1} + X_{t-2}$.

Exercice 5.2 (*). Appliquer `pm.auto_arima` à une série de votre choix. Interpréter le modèle sélectionné.

Exercice 5.3 (**). Montrer que si $X_t \sim \text{ARIMA}(p, 1, q)$, alors les prévisions à long terme convergent vers une droite (prévision constante en niveaux différenciés).

Exercice 5.4 (*** – Projet). Modéliser le PIB trimestriel d'un pays par un ARIMA saisonnier. Comparer les prévisions hors échantillon avec différents ordres.

Formules clés

$$\text{ARIMA}(p, d, q) : \phi(B)(1 - B)^d X_t = \theta(B)\varepsilon_t$$

$$\text{SARIMA} : \Phi(B^s)\phi(B)(1 - B)^d(1 - B^s)^D X_t = \Theta(B^s)\theta(B)\varepsilon_t$$

$$I(d) : \nabla^d X_t \text{ stationnaire, } \nabla^{d-1} X_t \text{ non}$$

Chapitre 6

Modèles GARCH et Volatilité Conditionnelle

En 1982, Robert Engle, économètre à l'Université de Californie à San Diego, observe sur les données d'inflation britannique et américaine un phénomène qu'aucun modèle ARMA ne peut capturer : la variance des résidus n'est pas constante, mais regroupée en grappes — les périodes calmes alternent avec des périodes turbulentes. Engle propose un modèle où la variance conditionnelle dépend des chocs passés : le processus ARCH (*AutoRegressive Conditional Heteroscedasticity*). Quatre ans plus tard, Tim Bollerslev généralise en GARCH en ajoutant un terme autorégressif sur la variance elle-même. Le résultat est devenu, depuis le krach de 1987, l'outil standard de modélisation de la volatilité en finance — au point que le prix Nobel d'économie 2003 récompense Engle pour cette innovation. Ce chapitre construit les modèles ARCH(q) et GARCH(p, q), présente les variantes (EGARCH d'Engle-Nelson, GJR-GARCH, IGARCH, FIGARCH), traite l'estimation par maximum de vraisemblance et applique le tout au calcul de Value-at-Risk.

6.1 Exemple motivant

Les rendements financiers sont approximativement non corrélés, mais leur carré r_t^2 montre une forte autocorrélation : les périodes de forte volatilité sont groupées (**volatility clustering**). Les modèles ARMA ne capturent pas ce phénomène.

6.2 Faits stylisés des rendements financiers

1. Rendements approximativement non corrélés : $\rho_r(h) \approx 0$.
2. Rendements au carré corrélés : $\rho_{r^2}(h) > 0$ (persistance de la volatilité).
3. Queues lourdes (leptokurtose) : kurtosis > 3 .
4. Asymétrie de la volatilité (effet de levier) : les baisses augmentent davantage la volatilité que les hausses.

6.3 Modèle ARCH

Définition 6.1 (ARCH(q)).

$$r_t = \sigma_t z_t, \quad z_t \stackrel{\text{iid}}{\sim} (0, 1), \quad \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i r_{t-i}^2,$$

où $\omega > 0$, $\alpha_i \geq 0$, et $\sum \alpha_i < 1$ pour la stationnarité.

Théorème 6.2 (Propriétés d'un ARCH(q)). 1. $\mathbb{E}[r_t] = 0$, $\text{Var}(r_t) = \omega / (1 - \sum \alpha_i)$.

2. (r_t) est un bruit blanc (non corrélé).

3. (r_t^2) suit un AR(q) : $r_t^2 = \omega + \sum \alpha_i r_{t-i}^2 + v_t$ où $v_t = r_t^2 - \sigma_t^2$ est un bruit blanc.

4. Kurtosis > 3 (queues lourdes même si z_t est gaussien).

6.4 Modèle GARCH

Définition 6.3 (GARCH(p, q)).

$$r_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i r_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2.$$

Conditions de stationnarité : $\omega > 0$, $\alpha_i, \beta_j \geq 0$, $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$.

Théorème 6.4 (Variance inconditionnelle GARCH(1, 1)).

$$\text{Var}(r_t) = \frac{\omega}{1 - \alpha_1 - \beta_1}.$$

La **persistence** de la volatilité est mesurée par $\alpha_1 + \beta_1$ (proche de 1 en finance).

Intuition

Le GARCH(1, 1) est le modèle de volatilité le plus utilisé en pratique. La prévision de la variance conditionnelle un pas en avant est :

$$\hat{\sigma}_{t+1}^2 = \omega + \alpha_1 r_t^2 + \beta_1 \sigma_t^2.$$

C'est une moyenne pondérée exponentielle des carrés passés.

6.5 IGARCH

Définition 6.5. Si $\alpha_1 + \beta_1 = 1$ (intégré GARCH), les chocs de volatilité persistent indéfiniment. Le processus n'est pas stationnaire au second ordre mais reste **strictement stationnaire**.

6.6 Extensions

6.6.1 EGARCH

Définition 6.6. Le modèle EGARCH de Nelson :

$$\ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - \mathbb{E}[|z_{t-1}|]) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2.$$

Le terme γz_{t-1} capture l'**effet de levier**. Pas de contrainte de positivité sur les paramètres.

6.6.2 GJR-GARCH

Définition 6.7.

$$\sigma_t^2 = \omega + (\alpha + \gamma \mathbf{1}_{r_{t-1} < 0}) r_{t-1}^2 + \beta \sigma_{t-1}^2.$$

$\gamma > 0$ implique que les rendements négatifs augmentent davantage la volatilité.

6.7 Estimation

Définition 6.8 (Quasi-maximum de vraisemblance). La log-vraisemblance conditionnelle gaussienne :

$$\ell(\boldsymbol{\theta}) = -\frac{1}{2} \sum_{t=1}^n \left(\ln \sigma_t^2 + \frac{r_t^2}{\sigma_t^2} \right).$$

Même si z_t n'est pas gaussien, le QMLE est consistant sous certaines conditions.

6.8 Tests d'effet ARCH

Définition 6.9 (Test ARCH-LM d'Engle). Régresser r_t^2 sur $r_{t-1}^2, \dots, r_{t-q}^2$ et tester la nullité jointe par $nR^2 \sim \chi^2(q)$.

6.9 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from arch import arch_model

# Simuler un GARCH(1,1)
np.random.seed(42)
n = 1000
```

```

omega, alpha, beta = 0.05, 0.10, 0.85
sigma2 = np.zeros(n)
r = np.zeros(n)
sigma2[0] = omega / (1 - alpha - beta)
for t in range(1, n):
    sigma2[t] = omega + alpha * r[t-1]**2 + beta * sigma2[t-1]
    r[t] = np.sqrt(sigma2[t]) * np.random.normal()

fig, axes = plt.subplots(3, 1, figsize=(12, 8))
axes[0].plot(r, lw=0.5)
axes[0].set_title('Rendements simulés (GARCH(1,1))')
axes[1].plot(r**2, lw=0.5, color='orange')
axes[1].set_title('$r_t^2$ (volatilité réalisée)')
axes[2].plot(np.sqrt(sigma2), lw=0.5, color='red')
axes[2].set_title('$\sigma_t$ (volatilité conditionnelle)')
plt.tight_layout()
plt.savefig('ch06_garch.pdf')
plt.show()

# Ajuster un GARCH(1,1)
am = arch_model(r, vol='Garch', p=1, q=1, dist='normal')
res = am.fit(dis='off')
print(res.summary())

# Prédiction de volatilité
forecasts = res.forecast(horizon=10)
print("Variance prévisionnelle:")
print(forecasts.variance.iloc[-1])

```

6.10 Exercices

Exercice 6.1 (*). Montrer qu'un ARCH(1) avec $r_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha r_{t-1}^2$ implique $\mathbb{E}[r_t^4] = 3\omega^2(1 + \alpha)/(1 - 3\alpha^2)$ (si $3\alpha^2 < 1$). En déduire la kurtosis.

Exercice 6.2 (**). Montrer que le GARCH(1, 1) peut s'écrire comme un ARCH(∞).

Exercice 6.3 (**). Démontrer que le processus r_t^2 d'un GARCH(1, 1) suit un ARMA(1, 1).

Exercice 6.4 (***) – Projet). Télécharger les rendements journaliers du S&P 500 sur 10 ans. Estimer un GARCH(1, 1), un EGARCH(1, 1) et un GJR-GARCH(1, 1). Comparer par AIC et analyser l'effet de levier.

Formules clés

$$\text{GARCH}(1, 1) : \sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \alpha + \beta < 1$$

$$\text{Var}(r_t) = \omega / (1 - \alpha - \beta)$$

$$\text{EGARCH} : \ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$$

Chapitre 7

Analyse Spectrale

En 1898, Arthur Schuster, physicien à Manchester, étudie les taches solaires et invente le *périodogramme* : une décomposition de l'énergie d'un signal en contributions par fréquence, qui révèle les périodicités cachées. Soixante-sept ans plus tard, en 1965, James Cooley (IBM) et John Tukey (Princeton) publient la transformée de Fourier rapide — un algorithme en $O(N \log N)$ au lieu de $O(N^2)$ qui rend le périodogramme calculable sur des séries de millions d'observations en quelques millisecondes. La FFT est rétroactivement reconnue comme l'un des dix algorithmes les plus influents du XX^e siècle ; elle traverse l'audio numérique, la sismologie, l'imagerie médicale, les communications sans fil. Ce chapitre construit l'analyse spectrale des séries temporelles : densité spectrale, transformation de Wiener-Khinchine, périodogramme et ses estimateurs corrigés (Welch, Bartlett, fenêtrage), filtres linéaires en fréquence, et le théorème de Wold de décomposition.

7.1 Exemple motivant

Un signal climatique contient des cycles de différentes périodes (journalier, annuel, El Niño). L'analyse spectrale décompose la variance totale par fréquence, révélant les périodicités cachées.

7.2 Densité spectrale

Définition 7.1 (Densité spectrale de puissance). Si $\sum_{h=-\infty}^{\infty} |\gamma(h)| < \infty$, la **densité spectrale** de (X_t) est :

$$f(\omega) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma(h) e^{-i\omega h}, \quad \omega \in [-\pi, \pi].$$

C'est la transformée de Fourier de la fonction d'autocovariance.

Théorème 7.2 (Propriétés de f). 1. $f(\omega) \geq 0$ pour tout ω .

2. f est paire : $f(\omega) = f(-\omega)$.

3. Relation inverse : $\gamma(h) = \int_{-\pi}^{\pi} f(\omega) e^{i\omega h} d\omega$.

4. $\gamma(0) = \text{Var}(X_t) = \int_{-\pi}^{\pi} f(\omega) d\omega$ (théorème de Parseval).

Esquisse de (1). Par le théorème de Herglotz, γ est semi-définie positive. Donc $f(\omega) = \frac{1}{2\pi} \sum \gamma(h) e^{-i\omega h} \geq 0$ (comme limite de formes quadratiques positives). $\square$

7.3 Spectres de processus classiques


Théorème 7.3 (Spectre d'un ARMA(p, q)).

$$f(\omega) = \frac{\sigma^2}{2\pi} \frac{|\theta(e^{-i\omega})|^2}{|\phi(e^{-i\omega})|^2}.$$

Exemple 7.4 (Spectre d'un AR(1)). $\phi(z) = 1 - \phi z$:

$$f(\omega) = \frac{\sigma^2}{2\pi} \frac{1}{|1 - \phi e^{-i\omega}|^2} = \frac{\sigma^2}{2\pi(1 - 2\phi \cos \omega + \phi^2)}.$$

Si $\phi > 0$: pic en $\omega = 0$ (basses fréquences dominantes). Si $\phi < 0$: pic en $\omega = \pi$.



7.4 Périodogramme

Définition 7.5 (Périodogramme). L'estimateur naïf de $f(\omega)$:

$$I_n(\omega) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\omega t} \right|^2.$$

Théorème 7.6 (Propriétés du périodogramme). 1. $\mathbb{E}[I_n(\omega_j)] \rightarrow f(\omega_j)$ pour les fréquences de Fourier $\omega_j = 2\pi j/n$.

2. $I_n(\omega_j)$ est un estimateur **non consistant** : $\text{Var}(I_n(\omega_j)) \not\rightarrow 0$.

3. Aux fréquences de Fourier : $I_n(\omega_j)/f(\omega_j) \stackrel{\text{approx}}{\sim} \chi^2(2)/2$.

Attention

Le périodogramme brut est très erratique. Il faut le lisser pour obtenir un estimateur consistant.

7.5 Estimation spectrale

7.5.1 Fenêtre spectrale (lissage)

Définition 7.7 (Périodogramme lissé).

$$\hat{f}(\omega) = \sum_{|h| \leq M} w(h) \hat{\gamma}(h) e^{-i\omega h},$$

où w est une **fenêtre** (Bartlett, Parzen, Tukey, etc.) et M est la **largeur de bande**.

7.5.2 Méthode paramétrique

Estimer un modèle $\text{AR}(p)$ par Yule–Walker ou Burg, puis utiliser le spectre théorique $\hat{f}(\omega) = \frac{\hat{\sigma}^2}{2\pi|\hat{\phi}(e^{-i\omega})|^2}$.

7.6 Implémentation

Python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.signal import periodogram, welch

# Simuler un AR(2) avec pic spectral
np.random.seed(42)
n = 1024
eps = np.random.normal(0, 1, n)
x = np.zeros(n)
phi1, phi2 = 1.5, -0.85 # racines complexes => pic
for t in range(2, n):
    x[t] = phi1*x[t-1] + phi2*x[t-2] + eps[t]

# Périodogramme brut
freq_p, Pxx_p = periodogram(x, fs=1, scaling='density')

# Périodogramme lissé (Welch)
freq_w, Pxx_w = welch(x, fs=1, nperseg=256, scaling='density')

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].semilogy(freq_p, Pxx_p, lw=0.5)
```

```

axes[0].set_title('Périodogramme brut')
axes[0].set_xlabel('Fréquence')

axes[1].semilogy(freq_w, Pxx_w, lw=1.5, color='red')
axes[1].set_title('Périodogramme lissé (Welch)')
axes[1].set_xlabel('Fréquence')

plt.tight_layout()
plt.savefig('ch07_spectral.pdf')
plt.show()

# Spectre théorique AR(2)
omega = np.linspace(0.01, np.pi, 500)
phi_z = 1 - phi1*np.exp(-1j*omega) - phi2*np.exp(-2j*omega)
f_theo = 1 / (2*np.pi * np.abs(phi_z)**2)

plt.figure(figsize=(8, 4))
plt.plot(omega, f_theo, 'b-', label='Théorique')
plt.title('Spectre théorique AR(2)')
plt.xlabel('$\omega$'); plt.ylabel('$f(\omega)$')
plt.legend()
plt.savefig('ch07_spectral_theo.pdf')
plt.show()

```

7.7 Exercices

Exercice 7.1 (*). Calculer la densité spectrale d'un MA(1) : $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$.

Exercice 7.2 (**). Montrer que le périodogramme peut s'écrire $I_n(\omega) = \sum_{|h|<n} \hat{\gamma}(h)e^{-i\omega h}/(2\pi)$.

Exercice 7.3 (**). Démontrer que pour un bruit blanc gaussien, $2nI_n(\omega_j)/\sigma^2 \sim \chi^2(2)$ aux fréquences de Fourier non nulles.

Exercice 7.4 (***) – Projet). Analyser le spectre des températures journalières de Paris sur 50 ans. Identifier les pics correspondant aux cycles annuel, semi-annuel et hebdomadaire.

Formules clés

$$f(\omega) = \frac{1}{2\pi} \sum_h \gamma(h)e^{-i\omega h}, \quad \gamma(h) = \int_{-\pi}^{\pi} f(\omega)e^{i\omega h}d\omega$$

$$f_{\text{ARMA}}(\omega) = \frac{\sigma^2 |\theta(e^{-i\omega})|^2}{2\pi |\phi(e^{-i\omega})|^2}$$

$$I_n(\omega) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\omega t} \right|^2$$

Chapitre 8

Modèles à Espace d'États et Filtre de Kalman

En 1960, Rudolf Kalman, ingénieur hongro-américain au Research Institute for Advanced Studies de Baltimore, publie un article qui changera l'histoire du contrôle automatique : *A New Approach to Linear Filtering and Prediction Problems*. Kalman propose un algorithme récursif qui maintient en temps réel la meilleure estimation de l'état caché d'un système linéaire perturbé par du bruit gaussien. Neuf ans plus tard, le filtre de Kalman est embarqué dans l'ordinateur de bord d'Apollo 11 pour calculer en continu la position du module lunaire pendant la descente. Aujourd'hui, il opère dans tout GPS, tout système d'inertie, toute centrale d'attitude. Ce chapitre construit la représentation espace-état (équation d'évolution, équation d'observation), démontre le filtre de Kalman et son lissage de Rauch-Tung-Striebel, présente les extensions (filtre de Kalman étendu, filtre de Kalman *unscented*, filtre particulaire) et applique le tout à l'estimation simultanée d'état et de paramètres.

8.1 Exemple motivant

Le PIB « vrai » d'une économie est inobservable ; on n'observe que des estimations bruitées et révisées. Un modèle à espace d'états sépare l'**état latent** de l'**observation bruitée** et le filtre de Kalman fournit l'estimation optimale de l'état.

8.2 Modèle linéaire gaussien à espace d'états

Définition 8.1 (Modèle à espace d'états).

$$\mathbf{x}_{t+1} = F\mathbf{x}_t + G\mathbf{w}_t \quad (\text{équation d'état}) \quad (8.1)$$

$$\mathbf{y}_t = H\mathbf{x}_t + \mathbf{v}_t \quad (\text{équation d'observation}) \quad (8.2)$$

où $\mathbf{x}_t \in \mathbb{R}^p$ est l'état (latent), $\mathbf{y}_t \in \mathbb{R}^m$ l'observation, $\mathbf{w}_t \sim \mathcal{N}(0, Q)$ et $\mathbf{v}_t \sim \mathcal{N}(0, R)$ sont indépendants.

Exemple 8.2 (Tendance locale (local level)). $x_{t+1} = x_t + w_t$, $y_t = x_t + v_t$. L'état est la « vraie valeur » lissée.

Exemple 8.3 (ARMA comme espace d'états). Tout ARMA(p, q) peut se mettre sous forme espace d'états. Par exemple, l'AR(1) $X_t = \phi X_{t-1} + \varepsilon_t$ correspond à $F = \phi$, $H = 1$, $G = 1$, $Q = \sigma^2$, $R = 0$.

8.3 Filtre de Kalman

Définition 8.4 (Filtre de Kalman). Notations : $\hat{\mathbf{x}}_{t|s} = \mathbb{E}[\mathbf{x}_t | \mathbf{y}_1, \dots, \mathbf{y}_s]$ et $P_{t|s} = \text{Cov}(\mathbf{x}_t - \hat{\mathbf{x}}_{t|s})$.

Prédiction :

$$\hat{\mathbf{x}}_{t+1|t} = F \hat{\mathbf{x}}_{t|t}, \quad (8.3)$$

$$P_{t+1|t} = F P_{t|t} F^\top + G Q G^\top. \quad (8.4)$$

Mise à jour :

$$K_t = P_{t|t-1} H^\top (H P_{t|t-1} H^\top + R)^{-1} \quad (\text{gain de Kalman}), \quad (8.5)$$

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + K_t (\mathbf{y}_t - H \hat{\mathbf{x}}_{t|t-1}), \quad (8.6)$$

$$P_{t|t} = (I - K_t H) P_{t|t-1}. \quad (8.7)$$

Théorème 8.5 (Optimalité du filtre de Kalman). *Dans le modèle linéaire gaussien, le filtre de Kalman donne l'estimateur MMSE (minimum mean square error) de $\mathbf{x}_t$ sachant $\mathbf{y}_1, \dots, \mathbf{y}_t$. C'est l'estimateur **optimal** parmi tous les estimateurs (pas seulement linéaires).*

Esquisse. Par récurrence. À chaque pas, la distribution conditionnelle $\mathbf{x}_t | \mathbf{y}_{1:t}$ est gaussienne (par fermeture de la loi gaussienne par conditionnement linéaire). L'espérance conditionnelle est l'estimateur MMSE pour les distributions gaussiennes. $\square$

8.4 Lisseur de Kalman

Définition 8.6 (Lisseur de Rauch–Tung–Striebel). Pour calculer $\hat{\mathbf{x}}_{t|n}$ (estimation de l'état passé avec toutes les observations) :

$$J_t = P_{t|t} F^\top P_{t+1|t}^{-1}, \quad (8.8)$$

$$\hat{\mathbf{x}}_{t|n} = \hat{\mathbf{x}}_{t|t} + J_t (\hat{\mathbf{x}}_{t+1|n} - \hat{\mathbf{x}}_{t+1|t}), \quad (8.9)$$

$$P_{t|n} = P_{t|t} + J_t (P_{t+1|n} - P_{t+1|t}) J_t^\top. \quad (8.10)$$

On itère en arrière de $t = n - 1$ à $t = 1$.

8.5 Vraisemblance par le filtre de Kalman

Théorème 8.7 (Décomposition de l'innovation). *La log-vraisemblance se décompose :*

$$\ln L = -\frac{nm}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^n [\ln |S_t| + \mathbf{e}_t^\top S_t^{-1} \mathbf{e}_t],$$

où $\mathbf{e}_t = \mathbf{y}_t - H \hat{\mathbf{x}}_{t|t-1}$ est l'**innovation** et $S_t = H P_{t|t-1} H^\top + R$.

8.6 Implémentation

Python

```
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.structural import UnobservedComponents

# Simuler un modèle local level
np.random.seed(42)
n = 200
sigma_w, sigma_v = 0.5, 1.0
x = np.zeros(n)
y = np.zeros(n)
for t in range(1, n):
    x[t] = x[t-1] + sigma_w * np.random.normal()
    y[t] = x[t] + sigma_v * np.random.normal()

# Filtre de Kalman manuel
F, H, Q, R = 1.0, 1.0, sigma_w**2, sigma_v**2
x_filt = np.zeros(n)
P_filt = np.zeros(n)
P_filt[0] = 1.0
for t in range(1, n):
    # Prédiction
    x_pred = F * x_filt[t-1]
    P_pred = F * P_filt[t-1] * F + Q
    # Mise à jour
    S = H * P_pred * H + R
    K = P_pred * H / S
    x_filt[t] = x_pred + K * (y[t] - H * x_pred)
    P_filt[t] = (1 - K * H) * P_pred

fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(y, 'o', ms=2, alpha=0.5, label='Observations $y_t$')
ax.plot(x, 'g-', lw=1.5, label='État vrai $x_t$')
ax.plot(x_filt, 'r--', lw=1.5, label='Filtre de Kalman $\hat{x}_{t|t}$')
ax.legend()
ax.set_title('Filtre de Kalman - Local Level Model')
plt.savefig('ch08_kalman.pdf')
plt.show()

# Avec statsmodels
model = UnobservedComponents(y, 'local level')
results = model.fit(dispatch=False)
print(results.summary())
```

8.7 Exercices

Exercice 8.1 (★). Écrire l'AR(2) sous forme espace d'états.

Exercice 8.2 (★★). Démontrer que le gain de Kalman K_t minimise $\text{tr}(P_{t|t})$.

Exercice 8.3 (★★). Montrer que dans le modèle local level stationnaire (σ_w, σ_v constants), le gain de Kalman converge vers une constante K_∞ .

Exercice 8.4 (★★★ – Projet). Implémenter un filtre de Kalman étendu (EKF) pour un modèle de volatilité stochastique : $\ln \sigma_t^2 = \phi \ln \sigma_{t-1}^2 + w_t$, $r_t = \sigma_t z_t$.

Formules clés

$$\begin{aligned}\hat{\mathbf{x}}_{t+1|t} &= F\hat{\mathbf{x}}_{t|t}, & P_{t+1|t} &= FP_{t|t}F^\top + GQG^\top \\ K_t &= P_{t|t-1}H^\top (HP_{t|t-1}H^\top + R)^{-1} \\ \hat{\mathbf{x}}_{t|t} &= \hat{\mathbf{x}}_{t|t-1} + K_t(\mathbf{y}_t - H\hat{\mathbf{x}}_{t|t-1}) \\ \ln L &= -\frac{1}{2} \sum [\ln |S_t| + \mathbf{e}_t^\top S_t^{-1} \mathbf{e}_t]\end{aligned}$$

Chapitre 9

Séries Temporelles Multivariées — VAR et Cointégration

En 1980, Christopher Sims publie dans *Econometrica* l'article *Macroeconomics and Reality*, dans lequel il attaque les modèles macroéconomiques structurels qui dominaient alors la profession : leurs identifications par restrictions *a priori*, dit Sims, sont des hypothèses « incroyables ». Sa proposition — traiter toutes les variables macroéconomiques symétriquement dans un modèle d'autorégression vectorielle (VAR) — révolutionne l'économétrie appliquée. Trente-trois ans plus tard, le prix Nobel d'économie 2011 récompense Sims pour cette contribution. Les VAR servent aujourd'hui aux banques centrales (Federal Reserve, BCE, Banque du Japon) pour analyser les transmissions de chocs et calibrer la politique monétaire. Ce chapitre construit les $\text{VAR}(p)$, démontre les conditions de stationnarité, présente l'identification structurelle (Cholesky, restrictions de long terme à la Blanchard-Quah, restrictions de signe), les fonctions de réponse impulsionnelle, et les modèles cointégrés VECM de Granger-Engle (1987).

9.1 Exemple motivant

Le taux d'intérêt et l'inflation évoluent conjointement : la hausse de l'un influence l'autre. Un modèle **VAR** capture ces interdépendances dynamiques. La **cointégration** révèle des relations d'équilibre long terme entre variables non stationnaires.

9.2 Processus vectoriels stationnaires

Définition 9.1 (Processus vectoriel stationnaire). $(\mathbf{Y}_t)_{t \in \mathbb{Z}}$ avec $\mathbf{Y}_t \in \mathbb{R}^k$ est **faiblement stationnaire** si :

1. $\mathbb{E}[\|\mathbf{Y}_t\|^2] < \infty$,
2. $\boldsymbol{\mu} = \mathbb{E}[\mathbf{Y}_t]$ ne dépend pas de t ,
3. $\Gamma(h) = \text{Cov}(\mathbf{Y}_t, \mathbf{Y}_{t+h}) = \mathbb{E}[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_{t+h} - \boldsymbol{\mu})^\top]$ ne dépend que de h .

Note : $\Gamma(h) = \Gamma(-h)^\top$ (mais $\Gamma(h) \neq \Gamma(h)^\top$ en général).

9.3 Modèle VAR(p)

Définition 9.2 (VAR(p)).

$$\mathbf{Y}_t = \mathbf{c} + A_1 \mathbf{Y}_{t-1} + A_2 \mathbf{Y}_{t-2} + \cdots + A_p \mathbf{Y}_{t-p} + \mathbf{u}_t,$$

où $\mathbf{u}_t \sim \text{BB}(\mathbf{0}, \Sigma_u)$ (k -dimensionnel) et $A_i \in \mathbb{R}^{k \times k}$.

Théorème 9.3 (Stationnarité d'un VAR(p)). *Le VAR(p) est stationnaire si et seulement si toutes les racines de*

$$\det(I_k - A_1 z - \cdots - A_p z^p) = 0$$

sont en dehors du disque unité.

9.3.1 Estimation

Théorème 9.4. *Les paramètres d'un VAR(p) peuvent être estimés équation par équation par OLS. L'estimateur est consistant et asymptotiquement normal.*

9.4 Causalité de Granger

Définition 9.5 (Causalité de Granger). $Y_{2,t}$ **cause au sens de Granger** $Y_{1,t}$ si les valeurs passées de Y_2 améliorent la prévision de Y_1 , i.e. si dans le VAR, les coefficients associés aux retards de Y_2 dans l'équation de Y_1 sont conjointement significatifs.

Test : $H_0 : A_1^{(12)} = \cdots = A_p^{(12)} = 0$ par test de Wald (F -test).

9.5 Fonctions de réponse impulsionnelle

Définition 9.6 (IRF). La **fonction de réponse impulsionnelle** mesure l'effet d'un choc unitaire sur $u_{j,t}$ sur $Y_{i,t+h}$:

$$\Psi_h = \frac{\partial \mathbf{Y}_{t+h}}{\partial \mathbf{u}_t^\top},$$

où $\mathbf{Y}_t = \sum_{h=0}^{\infty} \Psi_h \mathbf{u}_{t-h}$ est la représentation MA(∞).

9.6 Coïntégration

Définition 9.7 (Coïntégration). Des séries $I(1)$ $Y_{1,t}, \dots, Y_{k,t}$ sont **coïntégrées** s'il existe $\boldsymbol{\beta} \neq \mathbf{0}$ tel que $\boldsymbol{\beta}^\top \mathbf{Y}_t \sim I(0)$. Le vecteur $\boldsymbol{\beta}$ est un **vecteur de coïntégration** et $\boldsymbol{\beta}^\top \mathbf{Y}_t$ représente une relation d'équilibre long terme.

Exemple 9.8. Les prix spot et futures d'une matière première sont chacun $I(1)$, mais leur différence (la base) est $I(0)$: ils sont coïntégrés avec $\boldsymbol{\beta} = (1, -1)^\top$.

Définition 9.9 (Modèle à correction d'erreur (VECM)).

$$\nabla \mathbf{Y}_t = \Pi \mathbf{Y}_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \nabla \mathbf{Y}_{t-i} + \mathbf{u}_t,$$

où $\Pi = \alpha\beta^\top$ avec $\alpha \in \mathbb{R}^{k \times r}$ (vitesses d'ajustement) et $\beta \in \mathbb{R}^{k \times r}$ (vecteurs de coïntégration), $r = \text{rang}(\Pi)$ est le nombre de relations de coïntégration.

Théorème 9.10 (Représentation de Granger). *Si $\mathbf{Y}_t \sim I(1)$ et coïntégré de rang r :*

- $0 < r < k$: coïntégration. Le VECM est la bonne spécification.
- $r = 0$: pas de coïntégration, VAR en différences.
- $r = k$: toutes les séries sont $I(0)$, VAR en niveaux.

9.6.1 Test de Johansen

Définition 9.11. Le test de Johansen détermine le rang de coïntégration r par des tests séquentiels de la valeur propre maximale ou de la trace.

9.7 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.api import VAR
from statsmodels.tsa.vector_ar.vecm import coint_johansen

# Simuler un VAR(1) bivarié
np.random.seed(42)
n = 500
A = np.array([[0.5, 0.3], [-0.2, 0.6]])
Y = np.zeros((n, 2))
for t in range(1, n):
    Y[t] = A @ Y[t-1] + np.random.multivariate_normal([0,0],
                                                         [[1, 0.3],[0.3, 1]])

df = pd.DataFrame(Y, columns=['Y1', 'Y2'])

# Ajuster VAR
model = VAR(df)
results = model.fit(maxlags=5, ic='bic')
print(results.summary())

# Causalité de Granger
```

```
granger = results.test_causality('Y1', 'Y2', kind='f')
print(f"\nGranger Y2 -> Y1: p-value = {granger.pvalue:.4f}")

# IRF
irf = results.irf(20)
irf.plot(orth=True)
plt.savefig('ch09_irf.pdf')
plt.show()

# Coïntégration (Johansen) sur données simulées I(1)
rw1 = np.cumsum(np.random.normal(0, 1, n))
rw2 = 0.5 * rw1 + np.cumsum(np.random.normal(0, 0.3, n))
data_coint = np.column_stack([rw1, rw2])
joh = coint_johansen(data_coint, det_order=0, k_ar_diff=1)
print("\nJohansen trace stats:", joh.lr1)
print("Critical values (90%, 95%, 99%):", joh.cvt)
```

9.8 Exercices

Exercice 9.1 (★). Vérifier que le VAR(1) $\mathbf{Y}_t = A\mathbf{Y}_{t-1} + \mathbf{u}_t$ avec $A = \begin{pmatrix} 0,5 & 0 \\ 0 & 0,3 \end{pmatrix}$ est stationnaire. Calculer $\Gamma(0)$.

Exercice 9.2 (★★). Montrer que dans un VAR(1), $\Gamma(h) = A^h\Gamma(0)$ pour $h \geq 0$.

Exercice 9.3 (★★). Montrer que si $Y_{1,t}$ et $Y_{2,t}$ sont des marches aléatoires indépendantes, elles ne sont pas coïntégrées.

Exercice 9.4 (★★★ – Projet). Estimer un VAR pour le couple (taux d'intérêt, inflation) d'un pays. Tester la causalité de Granger dans les deux sens et interpréter les fonctions de réponse impulsionnelle.

Formules clés

$$\text{VAR}(p) : \mathbf{Y}_t = \mathbf{c} + A_1\mathbf{Y}_{t-1} + \cdots + A_p\mathbf{Y}_{t-p} + \mathbf{u}_t$$

$$\text{VECM} : \nabla\mathbf{Y}_t = \alpha\beta^\top\mathbf{Y}_{t-1} + \sum \Gamma_i\nabla\mathbf{Y}_{t-i} + \mathbf{u}_t$$

$$\text{Coïntégration} : \beta^\top\mathbf{Y}_t \sim I(0) \text{ avec } \mathbf{Y}_t \sim I(1)$$

Chapitre 10

Prévision et Intervalles de Confiance

En 1957, Charles C. Holt, ingénieur à la RAND, généralise le lissage exponentiel simple en l'étendant aux séries avec tendance ; en 1960, Peter R. Winters, son élève, l'étend à la saisonnalité. La méthode Holt-Winters — trois équations récursives qui mettent à jour niveau, tendance et saisonnalité à chaque nouvelle observation — est devenue le standard de facto de la prévision automatique en logistique et en gestion de stocks. La force de la méthode tient à sa simplicité : trois paramètres entre 0 et 1, calibrés une fois, fournissent des prévisions raisonnables pour des dizaines de milliers de séries simultanément. Aujourd'hui, ETS (Hyndman, Koehler, Snyder, Ord 2002), Prophet (Facebook 2017) et N-BEATS (Element AI 2019) prolongent cette tradition. Ce chapitre construit les méthodes de lissage exponentiel (SES, Holt, Holt-Winters), formalise les modèles ETS dans le cadre espace-état, démontre les intervalles de prévision, et compare aux modèles ARIMA via les compétitions M.

10.1 Exemple motivant

Prévoir la demande d'électricité pour le lendemain, avec un intervalle de confiance, est essentiel pour la gestion du réseau. La qualité de la prévision détermine les coûts économiques.

10.2 Prévision optimale

Définition 10.1 (Prévision optimale). La **prévision optimale** de X_{n+h} sachant $X_1, \dots, X_n$ au sens des moindres carrés est :

$$\hat{X}_{n+h|n} = \mathbb{E}[X_{n+h} | X_1, \dots, X_n].$$

L'erreur de prévision est $e_{n+h|n} = X_{n+h} - \hat{X}_{n+h|n}$.

Théorème 10.2 (Erreur quadratique moyenne). *L'espérance conditionnelle minimise l'EQM :*

$$\hat{X}_{n+h|n} = \arg \min_{g(X_1, \dots, X_n)} \mathbb{E}[(X_{n+h} - g)^2].$$

10.3 Prévision ARMA

Théorème 10.3 (Prévision d'un ARMA(p, q)). *En utilisant la représentation MA(∞) : $X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$, la prévision à h pas est :*

$$\hat{X}_{n+h|n} = \sum_{j=h}^{\infty} \psi_j \varepsilon_{n+h-j}.$$

L'erreur de prévision est $e_{n+h|n} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{n+h-j}$, de variance :

$$\sigma_h^2 = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Corollaire 10.4. *Pour un ARMA stationnaire, $\sigma_h^2 \rightarrow \gamma(0) = \text{Var}(X_t)$ quand $h \rightarrow \infty$: la prévision converge vers la moyenne inconditionnelle et l'intervalle de confiance s'élargit vers l'intervalle inconditionnel.*

10.4 Intervalles de prévision

Définition 10.5. Sous l'hypothèse gaussienne, un intervalle de prévision à $(1 - \alpha)$ pour X_{n+h} est :

$$\hat{X}_{n+h|n} \pm z_{1-\alpha/2} \sigma_h,$$

où $z_{1-\alpha/2}$ est le quantile de la loi normale.

Attention

Les intervalles de prévision ne tiennent pas compte de l'incertitude sur les paramètres estimés. Des méthodes de bootstrap ou de simulation peuvent être utilisées pour des intervalles plus réalistes.

10.5 Prévision ARIMA

Théorème 10.6. *Pour un ARIMA(p, d, q), la prévision à long terme du niveau X_{n+h} croît linéairement (si $d = 1$) ou quadratiquement (si $d = 2$) : l'intervalle de prévision s'élargit sans borne.*

10.6 Critères d'évaluation

Définition 10.7 (Métriques de prévision).

$$\text{MAE} = \frac{1}{H} \sum_{h=1}^H |e_{n+h|n}|, \quad (10.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{H} \sum_{h=1}^H e_{n+h|n}^2}, \quad (10.2)$$

$$\text{MAPE} = \frac{100}{H} \sum_{h=1}^H \frac{|e_{n+h|n}|}{|X_{n+h}|} \%. \quad (10.3)$$

Définition 10.8 (Validation croisée temporelle). Pour évaluer la capacité prédictive, on utilise un découpage **train/test** respectant l'ordre temporel (pas de shuffling). La méthode **rolling window** ou **expanding window** est standard.

10.7 Test de Diebold–Mariano

Définition 10.9. Pour comparer deux modèles de prévision, soit $d_t = L(e_{1,t}) - L(e_{2,t})$ la différence de perte. Sous H_0 (égalité) :

$$\text{DM} = \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/H}} \xrightarrow{d} \mathcal{N}(0, 1).$$

10.8 Implémentation

Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Simuler un ARMA(1,1)
np.random.seed(42)
from statsmodels.tsa.arima_process import ArmaProcess
ar = np.array([1, -0.7])
ma = np.array([1, 0.3])
data = ArmaProcess(ar, ma).generate_sample(nsample=300)

# Train/test split
train, test = data[:250], data[250:]

# Ajuster et prévoir
```

```

model = ARIMA(train, order=(1, 0, 1))
results = model.fit()

forecast = results.get_forecast(steps=50)
pred = forecast.predicted_mean
ci = forecast.conf_int(alpha=0.05)

# Métriques
mae = mean_absolute_error(test, pred)
rmse = np.sqrt(mean_squared_error(test, pred))
print(f"MAE = {mae:.4f}")
print(f"RMSE = {rmse:.4f}")

# Graphique
fig, ax = plt.subplots(figsize=(12, 5))
ax.plot(range(250), train, 'b-', lw=0.7, label='Train')
ax.plot(range(250, 300), test, 'g-', lw=1, label='Test')
ax.plot(range(250, 300), pred, 'r--', lw=1.5, label='Prévision')
ax.fill_between(range(250, 300), ci[:, 0], ci[:, 1],
                alpha=0.2, color='red')
ax.legend()
ax.set_title('Prévision ARMA(1,1)')
plt.savefig('ch10_forecast.pdf')
plt.show()

# Rolling forecast
rolling_preds = []
for i in range(len(test)):
    train_i = data[:250+i]
    model_i = ARIMA(train_i, order=(1,0,1)).fit()
    rolling_preds.append(model_i.forecast(steps=1)[0])
rmse_roll = np.sqrt(mean_squared_error(test, rolling_preds))
print(f"RMSE rolling: {rmse_roll:.4f}")

```

10.9 Exercices

Exercice 10.1 (★). Pour un AR(1) avec $\phi = 0,8$ et $\sigma^2 = 1$, calculer $\hat{X}_{n+1|n}$, $\hat{X}_{n+2|n}$ et les variances de prévision correspondantes.

Exercice 10.2 (★★). Montrer que la variance de prévision à h pas d'un AR(1) est $\sigma^2 \frac{1-\phi^{2h}}{1-\phi^2}$.

Exercice 10.3 (★★). Expliquer pourquoi le MAPE est problématique quand X_t prend des valeurs proches de zéro.

Exercice 10.4 (*** – Projet). Comparer les prévisions hors échantillon d'un ARIMA, d'un lissage exponentiel et d'un modèle naïf ($\hat{X}_{n+h} = X_n$) sur 5 séries réelles. Utiliser le test de Diebold–Mariano.

Formules clés

$$\hat{X}_{n+h|n} = \sum_{j=h}^{\infty} \psi_j \varepsilon_{n+h-j}, \quad \sigma_h^2 = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$$

$$\text{IC}_{95\%} : \hat{X}_{n+h|n} \pm 1,96 \sigma_h$$

$$\text{RMSE} = \sqrt{\frac{1}{H} \sum e_{n+h}^2}$$

Chapitre 11

Applications : Finance, Économie, Météorologie

De 1982 à aujourd'hui, le statisticien grec Spyros Makridakis organise les *M-Competitions* : des compétitions ouvertes de prévision sur des dizaines de milliers de séries réelles (économiques, financières, démographiques, industrielles) où chaque méthode publiée est évaluée par les mêmes métriques sur les mêmes données. Le verdict, répété de M1 (1982) à M5 (2020) : les méthodes les plus complexes ne battent pas systématiquement les plus simples. Holt-Winters tient tête à des modèles bayésiens élaborés ; l'ensemble bête de quatre méthodes simples a longtemps dominé la compétition annuelle. Le tournant survient en 2018-2020 quand les méthodes de *deep learning* (LSTM, N-BEATS, transformers temporels) et l'ensemble avec gradient boosting prennent enfin la tête. Ce chapitre passe en revue les applications majeures : prévision de la demande en supply chain, prédiction financière, prévision énergétique, suivi épidémiologique, et présente les compétitions M en détail comme banc d'essai canonique.

11.1 Exemple motivant

Les outils développés dans ce cours s'appliquent directement à des problèmes concrets : gestion de portefeuille, prévision macroéconomique, modélisation climatique.

11.2 Finance : Modélisation de la volatilité

11.2.1 Valeur à risque (VaR)

Définition 11.1 (VaR). La **Value at Risk** au niveau α est le quantile α de la distribution des pertes :

$$P(L_t > \text{VaR}_\alpha) = \alpha.$$

Avec un modèle GARCH : $\text{VaR}_\alpha = -\hat{\mu}_t + \hat{\sigma}_t q_\alpha$, où q_α est le quantile de la distribution des innovations.

11.2.2 Application

Python — VaR avec GARCH

```
import numpy as np
import pandas as pd
from arch import arch_model

# Simuler des rendements type financier
np.random.seed(42)
n = 2000
omega, alpha, beta = 0.01, 0.08, 0.90
sigma2 = np.zeros(n)
r = np.zeros(n)
sigma2[0] = omega / (1 - alpha - beta)
for t in range(1, n):
    sigma2[t] = omega + alpha * r[t-1]**2 + beta * sigma2[t-1]
    r[t] = np.sqrt(sigma2[t]) * np.random.standard_t(5)

# Estimer GARCH(1,1) avec innovations t de Student
am = arch_model(r * 100, vol='Garch', p=1, q=1, dist='t')
res = am.fit(dispatch='off')

# VaR 1%
forecasts = res.forecast(horizon=1)
sigma_next = np.sqrt(forecasts.variance.values[-1, 0])
from scipy.stats import t as t_dist
nu = res.params['nu']
VaR_01 = sigma_next * t_dist.ppf(0.01, nu)
print(f"VaR 1% = {VaR_01:.4f}%")
```

11.3 Économie : Prévion macroéconomique

11.3.1 PIB et indicateurs avancés

Méthode

1. Charger les séries trimestrielles (PIB, consommation, investissement).
2. Tester la stationnarité (ADF). Différencier si nécessaire.
3. Estimer un VAR ou un ARIMA saisonnier.
4. Évaluer par validation hors échantillon.

Python — Prévion macro

```

import pandas as pd
import numpy as np
from statsmodels.tsa.api import VAR
from statsmodels.tsa.stattools import adfuller

# Exemple avec données simulées (remplacer par FRED/Eurostat)
np.random.seed(0)
n = 200
gdp = np.cumsum(np.random.normal(0.5, 1, n))      # trend + bruit
cpi = 0.3 * gdp + np.cumsum(np.random.normal(0, 0.5, n))

df = pd.DataFrame({'GDP_growth': np.diff(gdp),
                   'Inflation': np.diff(cpi)})

# VAR
model = VAR(df)
results = model.fit(ic='bic')
print(f"Ordre sélectionné: VAR({results.k_ar})")
print(results.summary())

# Prévion
forecast = results.forecast(df.values[-results.k_ar:], steps=8)
print("Prévion PIB (8 trimestres):", forecast[:, 0])

```

11.4 Météorologie : Températures et saisonnalité

Python — Série de températures

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.statespace.sarimax import SARIMAX

# Simuler des températures mensuelles
np.random.seed(42)
n_years = 30
t = np.arange(n_years * 12)
seasonal = 10 * np.sin(2 * np.pi * t / 12)
trend = 0.01 * t # réchauffement
noise = np.random.normal(0, 2, len(t))
temp = 15 + trend + seasonal + noise

df = pd.DataFrame({'temp': temp},
                  index=pd.date_range('1990-01', periods=len(t), freq='ME'))

```

```
# Décomposition
decomp = seasonal_decompose(df['temp'], model='additive', period=12)
decomp.plot()
plt.savefig('ch11_decomp.pdf')
plt.show()

# SARIMA
train = df.iloc[:-24]
test = df.iloc[-24:]
model = SARIMAX(train, order=(1,0,1),
                 seasonal_order=(1,1,1,12))
results = model.fit(dispatch=False)
pred = results.forecast(steps=24)

rmse = np.sqrt(np.mean((test['temp'] - pred.values)**2))
print(f"RMSE prévision 24 mois: {rmse:.2f}°C")
```

11.5 Résumé méthodologique

Domaine	Modèle typique	Enjeu principal
Finance	GARCH, EGARCH	Volatilité, queues lourdes
Macroéconomie	VAR, VECM, ARIMA	Causalité, cointégration
Météorologie	SARIMA, espace d'états	Saisonnalité, tendance
Épidémiologie	SIR + espace d'états	Non-linéarité
Signal	Analyse spectrale	Périodicités cachées

11.6 Exercices

Exercice 11.1 (*). Calculer la VaR à 5% pour un GARCH(1,1) avec $\hat{\sigma}_{t+1} = 2\%$ et innovations gaussiennes.

Exercice 11.2 (**). Comparer la prévision SARIMA et le lissage exponentiel de Holt–Winters sur les températures mensuelles. Lequel est le plus précis ?

Exercice 11.3 (***) – Projet). Choisir un jeu de données réel dans l'un des trois domaines. Appliquer la méthodologie complète : exploration, modélisation (au moins 3 modèles), diagnostic, prévision hors échantillon, comparaison. Rédiger un rapport de 10 pages.

Formules clés

$$\begin{aligned}\text{VaR}_\alpha &= -\hat{\mu}_t + \hat{\sigma}_t q_\alpha \\ \text{RMSE} &= \sqrt{\frac{1}{H} \sum (X_{n+h} - \hat{X}_{n+h})^2} \\ \text{DM} &= \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/H}} \xrightarrow{d} \mathcal{N}(0, 1)\end{aligned}$$

Formulaire

.1 Processus ARMA

$$\text{AR}(p) : X_t = \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t \quad (1)$$

$$\text{MA}(q) : X_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} \quad (2)$$

$$\text{ARMA}(p, q) : \phi(B)X_t = \theta(B)\varepsilon_t \quad (3)$$

$$\text{ARIMA}(p, d, q) : \phi(B)(1 - B)^d X_t = \theta(B)\varepsilon_t \quad (4)$$

.2 Autocovariance et autocorrélation

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) \quad (5)$$

$$\rho(h) = \gamma(h)/\gamma(0) \quad (6)$$

$$\hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-h} (X_t - \bar{X})(X_{t+h} - \bar{X}) \quad (7)$$

.3 Critères d'information

$$\text{AIC} = -2 \ln L + 2k \quad (8)$$

$$\text{BIC} = -2 \ln L + k \ln n \quad (9)$$

.4 GARCH

$$\text{GARCH}(1, 1) : \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (10)$$

.5 Filtre de Kalman

$$\text{État : } \mathbf{x}_{t+1} = F\mathbf{x}_t + \mathbf{w}_t \quad (11)$$

$$\text{Observation : } \mathbf{y}_t = H\mathbf{x}_t + \mathbf{v}_t \quad (12)$$

.6 VAR

$$\text{VAR}(p) : \mathbf{Y}_t = \mathbf{c} + A_1\mathbf{Y}_{t-1} + \cdots + A_p\mathbf{Y}_{t-p} + \mathbf{u}_t \quad (13)$$

Bibliographie

- [1] BOX, G.E.P., Jenkins, G.M., Reinsel, G.C. & Ljung, G.M. (2015). *Time Series Analysis : Forecasting and Control*. 5e éd., Wiley.
- [2] BROCKWELL, P.J. & Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. 3e éd., Springer.
- [3] HAMILTON, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- [4] SHUMWAY, R.H. & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*. 4e éd., Springer.
- [5] GOURIÉROUX, C. & Monfort, A. (1995). *Séries Temporelles et Modèles Dynamiques*. 2e éd., Economica.
- [6] TSAY, R.S. (2010). *Analysis of Financial Time Series*. 3e éd., Wiley.